




DeepLabV3+ ile Sismik Fasiyes Sınıflandırması

F3 Bloğu, Hollanda Üzerinde Aşamalı Mimari İyileştirmeler

Mehmet Furkan Kisli — Altı jeolojik sınıf boyunca otomatik sismik fasiyes bölütlemesi için beş DeepLabV3+ yapılandırmasının, kodlayıcı kapasitesi, giriş boyutluluğu, kayıp tasarımı ve yönsel eğitim stratejisini kapsayan sistematik bir ablation çalışması.

DEEPLABV3+

F3 BLOĞU, HOLLANDA

ANLAMSAZ BÖLÜTLEME

EFFICIENTNET-B4

Giriş: Otomatik Sismik Yorumlamanın Zorluğu

Sismik fasiyes sınıflandırması, sismik stratigrafik yorumlamanın temel bir adımıdır ve jeobilimcilerin farklı yansıma özelliklerine sahip yeraltı jeolojik gövdelerini ayırt etmesini sağlar. Geleneksel olarak bu süreç, alan uzmanlarının yaptığı manuel anotasyona dayanır — bu ise **zaman alıcı, öznel ve modern keşif kampanyalarında elde edilen giderek artan 3B sismik veri hacmiyle ölçeklenebilir değildir**.

Derin öğrenmenin ortaya çıkışı, otomatik sismik yorumlamayı dönüştürmüştür. Evrişimsel sinir ağları (CNN'ler) ve bunların kodlayıcı-kod çözücü türevleri, F3 Bloku Hollanda veri kümesi gibi herkese açık ölçütlerde güçlü performans göstermiştir. Bu yöntemler, her bir 2B sismik kesiti bir görüntü bölütleme problemi olarak ele alır ve her piksele bir jeolojik sınıf etiketi atar. Ancak iki sık göz ardı edilen zorluk devam etmektedir:

Yönsel Genelleme

Yalnızca inline kesitler üzerinde eğitilen modeller, aynı 3B hacmin dik açılı görüntü geometrisi nedeniyle crossline kesitlerde çoğu zaman başarısız olur. Bu bir veri kapsama problemidir — model jeolojik yapıları hiç dik yönden görmemiştir.

Mekânsal Bağlam

Her 2B kesit bağımsız olarak işlendiğinden, ince jeolojik katmanlar arasındaki sınırların belirlenmesine yardımcı olabilecek derinlik yönlü süreklilik bilgisi göz ardı edilir. Komşu kesitler, tek kanallı yaklaşımların terk ettiği değerli kesitler arası süreklilik ipuçları taşır.


Bu çalışma, F3 ölçütünde beş DeepLabV3+ yapılandırmasının sistematik bir incelemesini sunmakta; yönsel eğitimin, kodlayıcı kapasitesinin, kayıp tasarımının ve 2.5B girdinin hem inline hem de crossline genellemesi üzerindeki etkisini araştırmaktadır.

F3 Blok Hollanda Veri Kümesi

Veri Kümesine Genel Bakış

F3 Blok Hollanda veri kümesi, Kuzey Denizi'nden alınmış ve boyutları **401 × 701 × 255** (inline × crossline × derinlik) olan kamuya açık bir 3B sismik hacimdir. Altı jeolojik fasiyes etiketi sağlar ve Alaudah ve ark. [1] tarafından kullanılan eğitim/test ayrımını izler. Test1, eğitim hacminde yer almayan inline kesitlerden oluşur; Test2 ise crossline kesitlerinden oluşur — böylece hem aynı yön içi performans hem de yönler arası genelleme değerlendirilir.

Sınıf Dağılımı (Eğitim Kümesi)



- ❏ **Ana Zorluk:** Zechstein (S4, turuncu) inline görünümde geniş yatay bir yansıtıcı olarak ortaya çıkarken, crossline görünümde geometrik olarak sıkışır; bu da tüm model sürümlerinde süregelen crossline sınıflandırma zorluğunu açıklar.

Yöntem: DeepLabV3+ Mimarisi ve Girdi Stratejileri

DeepLabV3+ Çekirdeği

Çoklu ölçekli bağlamsal özellikleri seyrek evrişimler aracılığıyla yakalayan hafif bir çözücüyle atrous evrişimleri birleştirir. ASPP modülü, farklı oranlarda seyrekleştirilmiş evrişimler kullanarak çok ölçekli bağlamsal özellikleri yakalar — bu yapı, sismik stratigrafideki uzamsal ölçek çeşitliliği için özellikle uygundur. ASPP oranları: v3/v4 için (6, 12, 18); daha geniş jeolojik bağlamı yakalamak için v5–v7 için (12, 24, 36).

Kodlayıcı Yapılandırmaları

Ablağın boyunca beş kodlayıcı yapılandırması incelenmiştir: **ResNet-34** (v3), **ResNet-50** (v4 ve v5-2.5D ablation), ve **EfficientNet-B4** (v5, v6, v7). ResNet'ten EfficientNet-B4'e doğru ilerleme, ince jeolojik sınırları ayırt etme için temsil kapasitesini sistematik olarak artırır.

1 Kanallı ve 2.5D Girdi

v3–v5 sürümleri tek kanallı bir sismik genlik dilimi kullanır. v6 ve v7 sürümleri ise bir **2.5D girdi stratejisi** benimser: art arda üç dilim (önceki, mevcut, sonraki) C=3 giriş tensörü olarak istiflenir ve dilimler arası süreklilik bağlamı sağlar. Bu tasarım, 3 kanallı ImageNet önceden eğitilmiş ağırlıklarla uyumludur ve ağırlıkların doğrudan aktarılmasını mümkün kılar.

Çözünürlük İlerlemesi

6. sürüm, Mixup artırması olmadan **256 × 256** giriş çözünürlüğü kullanır ve çözünürlük ile Mixup'un katkılarını ayrı ayrı izole etmek için ara bir ablasyon görevi görür. 7. sürüm, çözünürlüğü **320 × 320**'ye çıkarır ve Mixup'u yeniden devreye alarak tüm metriklerde en iyi genel sonuçları elde eder.

Eğitim Stratejisi: Kayıp, Artırma ve Yönsel Öğrenme

Kayıp Fonksiyonunun Evrimi

v3: Basit 0.5 L_CE + 0.5 L_Dice birleşimi.

v4, v5, v7 (Üçlü Kayıp):

$$\mathcal{L} = 0.4\mathcal{L}_{CE}^{LS} + 0.3\mathcal{L}_{Dice} + 0.3\mathcal{L}_{Focal}(\gamma = 2)$$

burada etiket yumuşatmalı L_CE ($\epsilon = 0.1$), Etkin Örnek Sayısı sınıf ağırlıklarını uygular ve L_Focal, $\gamma = 2$ ile S5 gibi zor azınlık örneklerine odaklanarak eğitimi yönlendirir. v6 ve v5-2.5D sürümleri 0.5 L_Focal + 0.5 L_Dice kullanır.

S4 Çapraz Kesit Aşırı Örnekleme

v4 sonuçlarının analizi, S4 (Zechstein) için Test1 üzerinde %81.78 IoU elde edilirken Test2 üzerinde yalnızca %23.87 IoU sağlandığını göstermektedir. v5 ve v7 sürümleri, S4 piksellerinin kesit alanının %5'ini aştığı çapraz kesitler için **3x ağırlıklı WeightedRandomSampler** uygular.


Artırma ve Düzenleme

- Tüm sürümler: yatay çevirme, parlaklık/kontrast titretmesi, Gauss gürültüsü
- v4'ten itibaren: ElasticTransform, ShiftScaleRotate, CoarseDropout
- v6'dan itibaren: ayrıca GridDistortion uygulanır
- v5 ve v7: **Mixup ($\alpha = 0.2$, %50 olasılık)** — S3/S4/S5 arayüzünde daha yumuşak karar sınırlarını teşvik eder

Yönsel Eğitim — Kritik Müdahale

v3 sürümü yalnızca inline eğitim kullanır. v4'ten itibaren, modelin her iki bakış yönüne aynı anda maruz kalmasını sağlamak için inline ve çapraz kesitler **ConcatDataset** ile birleştirilir. Bu, tüm sürümler arasında **tek başına en etkili müdahaledir** ve tek bir adımda Test2 mIoU'da +41.3 yüzde puanı sağlar.

Ana Sonuçlar: Tüm Yapılandırmalar Arasında Nicel Karşılaştırma



v3 → v4 geçişi en büyük tekil iyileşmeyi sağlar: Test2 mIoU, yalnızca çok yönlü eğitim sayesinde **%27.10'dan %68.38'e (+41.3 puan)** yükselir. Nihai modelimiz v7, tüm metriklerde en iyi sonucu elde eder: birleşik mIoU **%79.26**, Piksel Doğruluğu **%94.13** ve Ortalama Sınıf Doğruluğu **%89.75**. ResNet-50 kullanan 2.5D ablasyonu (v5-2.5D), tüm EfficientNet yapılandırmalarının gerisinde kalır; bu da 2.5D bağlamın faydalı olabilmesi için kodlayıcı kapasitesinin gerekli bir koşul olduğunu doğrular. Tüm modeller, CosineAnnealingWarmRestarts ile AdamW ($T_0 = 25$, $\eta_{\min} = 10^{-6}$), max_norm = 1.0 ile gradyan kırpma ve NVIDIA RTX 4070 GPU üzerinde AMP kullanır. Çıkarımda TTA (orijinal ve yatay çevrilmiş softmax çıktılarının ortalaması) uygulanır.

79.26%

Birleşik mIoU

Tüm sürümler arasında en iyi — v7 (EfficientNet-B4, 2.5D, 320×320)

94.13%

Piksel Doğruluğu

Birleşik test kümesi — Alaudah ve ark. Section CNN temel çizgisini (%92.2) aşar

89.75%

Ortalama Sınıf Doğruluğu

Birleşik test kümesi — Section CNN temel çizgisini (%83.9) aşar


+41.3pp

Test2 mIoU Kazancı

v3'ten v4'e çok yönlü eğitim sayesinde — baskın tek müdahale

Sınıf Bazlı Analiz ve Eğitim Dinamikleri

Birleşik Test Setinde Sınıf Bazlı IoU (%)



Eğitim Dinamikleri — v7 (100 Epoch)

v7 için eğitim ve doğrulama eğrileri, CosineAnnealingWarmRestarts öğrenme oranı çizelgesine özgü sıcak yeniden başlatma salınımlarının belirgin olduğu, kaybın 100 epoch boyunca istikrarlı biçimde yakınsadığını göstermektedir. Doğrulama mIoU değeri son yeniden başlatma döngüsü boyunca kademeli olarak artarak 100. epoch'ta 0.66'ya ulaşmakta, bu da modelin aşırı öğrenme göstermediğini işaret etmektedir. Doğrulama metrikleri, aşırı öğrenme belirtisi olmaksızın dört yeniden başlatma döngüsünün tamamında iyileşmeye devam etmektedir.

Kayıp Yakınsaması

Eğitim ve doğrulama kaybı, kosinüs yeniden başlatma çizelgesinden kaynaklanan periyodik salınımlarla birlikte istikrarlı biçimde azalır — sapma ya da kararsızlık gözlenmez.

Doğrulama mIoU


Dört yeniden başlatma döngüsünün tamamı boyunca kademeli iyileşme gösterir, 100. epoch'ta 0.66'ya ulaşır — 100 epoch'luk eğitime rağmen aşırı öğrenme belirtisi yoktur.

Öğrenme Oranı Çizelgesi

CosineAnnealingWarmRestarts ($T_0 = 25$), optimize edicinin yerel minimumlardan kaçmasını sağlayan dört belirgin yeniden başlatma döngüsü üretir.

Çapraz Hat Genelleme Açığı ve Segmentasyon Görselleştirmesi

Her Sınıf için IoU: Test1 (Hat İçi) ile Test2 (Çapraz Hat) Karşılaştırması – v7



Karmaşıklık Matrisi Analizi (v7, Birleşik)

Normalize edilmiş karmaşıklık matrisi, S0, S1 ve S2'nin 0.91'in üzerinde diyagonal baskınlık gösterdiğini ortaya koymaktadır. S3 (Scruff), ince yanal yayılımı nedeniyle S2 ve S5 ile %9 oranında karışım göstermektedir. S4 (Zechstein), S3'e %9 ve S5'e %6 sızıntı göstermektedir. S5, %92 doğrulukla tüm sürümler arasındaki en iyi performansına ulaşmaktadır. S4 sızıntısı, evaporit tabakasının geometrik olarak sıkıştığı pozitif test bölünmesinde baskın hale gelmektedir.

Segmentasyon Görselleştirmesi

v7 için hem hat içi hem de çapraz hat test kesitlerinde yan yana gösterilen segmentasyon sonuçları, modelin hat içi kesitlerde altı sınıfın tamamını yüksek mekânsal doğrulukla doğru biçimde ayırdığını göstermektedir. Çapraz hat kesitlerde ise S0, S1, S2 ve S5 iyi segmentlenirken, **S4 sıklıkla yanlış sınıflandırılmakta ya da hiç görünmemektedir**; bu durum nicel sonuçlarla tutarlıdır ve çoğu zaman S5 (Zechstein Altı) ile karıştırılmaktadır.

Benchmark Karşılaştırması ve Temel Tartışma Bulguları

Alaudah ve ark. [1] Temelleriyle Karşılaştırma (Birleşik)

Yöntem	PA (%)	MCA (%)	mIoU (%)
Patch CNN [1]	90.5	81.7	Yok
Section CNN [1]	92.2	83.9	Yok
DeepLabV3+ v3 (bizim)	69.5	54.8	40.1
DeepLabV3+ v4 (bizim)	93.5	84.0	76.8
DeepLabV3+ v5 (bizim)	93.7	87.2	78.0
DeepLabV3+ v6 (bizim)	93.0	88.1	76.9
DeepLabV3+ v5-2.5D †	92.9	87.6	75.8
DeepLabV3+ v7 (bizim)	94.1	89.8	79.3

v7, PA'da %94.13 ve MCA'da %89.75 elde ederek her iki ölçütte de Section CNN'i (%92.2, %83.9) geride bırakır — bu, orijinal F3 Block benchmark temellerine kıyasla önemli bir iyileşmedir.

Yönlü Eğitim Baskın Geliyor

Tüm sürümler arasındaki en etkili tek tasarım kararı çok yönlü eğitimidir (v3 → v4, Test2 mIoU'da +41.3 puan). Bu, v3'teki çapraz hat genelleme başarısızlığının bir **veri kapsama sorunu** olduğunu doğrular: model, jeolojik yapıların dik görüş yönünden görünümünü hiç görmemiştir. Sonraki tüm iyileştirmeler bu temelin üzerine kurulmuştur.

Kodlayıcı Kapasitesi Bir Önkoşuldur

2.5D bağlamın faydası **kodlayıcı kapasitesine bağlıdır**. v5-2.5D varyantı (ResNet-50, 2.5D), birleşik mIoU'da v5'ten (EfficientNet-B4, 1-kanal) daha kötü performans gösterir (%75.82'ye karşı %77.99) ve 54. epokta erken yakınsar. Daha zayıf bir kodlayıcı, uzamsal olarak ilişkili kanallar ile ince dilimler arası farklılıkları ayırt edecek temsil kapasitesine sahip olmayabilir.

Kalıcı S4 Zechstein Sorunu

Hedefe yönelik müdahalelere (aşırı örnekleme, Mixup, daha güçlü kodlayıcı, 2.5D bağlam) rağmen S4 (Zechstein) çapraz hat IoU'su tüm sürümlerde %18'in altında kalır. Bu durum, evaporit dizilerinin **geometrik anizotropisine** bağlanır — 2D ve sahte-3D yaklaşımların yapısal bir sınırlaması. Tam 3D hacimsel bir mimari, en ilkesel çözüm olurdu.

Sonuçlar ve Gelecek Yönelimler

DeepLabV3+ modelinin F3 Block Netherlands veri setinde sismik fasiyes segmentasyonu için ilerleyici bir ablasyon çalışmasını sunduk. Son modelimiz v7 (EfficientNet-B4 kodlayıcı, 2.5D üç kanallı komşu dilim girdisi, 320×320 çözünürlük, Focal+Dice kaybı, S4/S5 aşırı örnekleme, Mixup artırımı), **79.26%** birleşik mIoU, **94.13%** PA ve **89.75%** MCA elde ederek tüm önceki yapılandırmaları ve Alaudah ve ark. temel karşılaştırmalarını geride bırakmaktadır. Ara yapılandırma olan v6, güçlü bir kodlayıcıyla 2.5D bağlamın ResNet-50 2.5D temelini aşmak için yeterli olduğunu doğrularken, v6 → v7 adımı ise daha yüksek çözünürlüğün ve Mixup düzenlileştirmesinin ek katkısını (+2.34 yüzde puanı birleşik mIoU) izole etmektedir.

1 Çok Yönlü Eğitim Baskın Faktördür

Çapraz çizgi genellemesindeki tek en etkili müdahale, yalnızca veri kapsamı yoluyla +41.3 yüzde puanlık Test2 mIoU farkını çözmektir. Sonraki tüm mimari iyileştirmeler bu temel üzerine inşa edilmiştir.

2 Güçlü Kodlayıcı + 2.5D Bağlam: Gerekli Bir Bileşim

2.5D uzamsal bağlam tutarlı iyileşmeler sağlar, ancak yalnızca yeterli kodlayıcı kapasitesiyle eşleştirildiğinde. ResNet-50 2.5D ablasyonu, EfficientNet-B4 1-kanallı varyantın gerisinde kalmakta; bu da temsil gücünün komşu dilim sürekliliğinden yararlanmak için bir önkoşul olduğunu doğrulamaktadır.

3 S4 Zechstein Çapraz Çizgi Problemi Yapısal Olarak Dirençlidir

Evaporit dizilerinin geometrik anizotropisi, tüm 2D ve psödo-3D yaklaşımlarda kalıcı çapraz çizgi başarısızlığına (18% IoU'nun altında) yol açar. Bu, derinlik eksenini modellemesi açıkça tanımlanmış tam 3D hacimsel mimariler gerektiren temel bir sınırlamadır.

Mevcut Sınırlamalar

- Tüm deneyler tek bir veri seti üzerinde (F3 Block Netherlands) yürütülmüştür; bu da genellenebilirliği sınırlar
- Modeller, tam 3D uzamsal bilgiye erişmeden dilimleri bağımsız olarak veya sınırlı bağlamla işlemektedir
- Belirsizlik nicelleştirmesi eksiktir; bu da pratik kullanım için önemlidir
- 320×320 girdi ile EfficientNet-B4'ün hesaplama maliyeti, RTX 4070 üzerinde epoch başına yaklaşık 14 saniyedir

Gelecek Çalışmalar

- 3D Hacimsel Mimariler:** S4 çapraz çizgi anizotropi problemini ele almak için açık derinlik eksenini modellemesine sahip tam 3D U-Net veya dikkat tabanlı 3D kodlayıcı
- Fizik Rehberli Kayıp Terimleri:** Jeolojik öncüllerin ve stratigrafik süreklilik kısıtlarının eğitim amacına dahil edilmesi
- Belirsizlik Farkındalıklı Tahmin:** Pratik yeraltı karakterizasyonu kullanımı için tahmin güvenini nicelleştirmek amacıyla Bayesçi veya topluluk yöntemleri