

DeepLabV3+ v7

2.5D Multi-View Sismik Fasiyes Segmentasyonu

Adim Adim Teknik Aciklama — F3 Block Netherlands

EfficientNet-B4 • ASPP • Focal+Dice+LS-CE Loss • Mixup • TTA

v6 → v7 Ana Degisiklikler

Degisiklik	v6	v7
Cozunurluk	256x256	320x320
Mixup augmentation	Yok	Var (alpha=0.2)
Label smoothing	Yok	Var (eps=0.1)
Loss fonksiyonu	0.5*Focal + 0.5*Dice	0.4*LS-CE + 0.3*Dice + 0.3*Focal
Batch size	8	6 (VRAM nedeniyle)
Encoder	Ayni	EfficientNet-B4
Diger her sey	Ayni	Ayni

0. Kurulum ve Cihaz Secimi

Ne yapiliyor?

Notebookun calisabilmesi icin gereken Python kutuphaneleri yukleniyor ve egitim icin kullanılacak donanim (GPU / CPU) tespit ediliyor.

Neden bu kutuphaneler?

Kutuphane	Gorevi
matplotlib	Gorsellestirme — egitim egrileri, fasiyes haritasi, confusion matrix
scikit-learn	confusion_matrix() hesabi — metrik fonksiyonlarinda kullanilir
alumentations	Hizli goruntu augmentasyon kutuphanesi (OpenCV tabanlı)
segmentation-models-pytorch (SMP)	DeepLabV3+ mimarisini hazir sunar; biz sadece parametreleri seciyoruz

Cihaz secimi — neden onemli?

- CUDA (NVIDIA GPU): En hizli. Otomatik Karisik Hassasiyet (AMP) aktif olur → VRAM tasarrufu ve hiz.
- MPS (Apple Silicon): Mac icin GPU hizlandirma.
- CPU: Yavastir; kucuk testler icin uygundur.

SEED = 42 neden sabitliyoruz?

random, numpy ve torch'un rastgele sayi ureticileri ayni tohumla baslatiliyor. Bu sayede her calistirmada ayni veri karistirma, ayni agirlik baslangici elde ediliyor. Sonuclar tekrarlanabilir oluyor — baska biri kodu calistirdiginda ayni sonucu gorur.

Dizin yapisi

Olusturulan Klasorler

data/: Ham sismik veri (.npy dosyalari)

checkpoints_v6/: Egitim sirasinda kaydedilen model snapshottlari

results_v6/figures/: PNG grafik ciktilari

results_v6/metrics/: JSON formatinda sayisal sonuclar

1. Veri Yükleme — F3 Block Netherlands

F3 Block Nedir?

Hollanda Kuzey Denizi'nden alınmış gerçek bir sismik aralık veri setidir. Alaudah ve ark. (2019) tarafından açık kaynak olarak yayınlanmıştır. İçerisinde 6 farklı jeolojik fasiyes sınıfını barındıran 3 boyutlu sismik amplitud volumleri bulunur.

Veri formatı ve boyutlar

Dosya	Boyut	Acıklama
train_seismic.npy	(401, 701, 255)	Eğitim volumunun amplitud değerleri
train_labels.npy	(401, 701, 255)	Eğitim volumunun fasiyes etiketleri (0-5)
test1_seismic.npy	(100, 701, 255)	Test seti 1 — inline kesitleri
test2_seismic.npy	(401, 100, 255)	Test seti 2 — crossline kesitleri

Eksenlerin anlamı

- **Eksen 0 (Inline):** Kaynaktan verici yönünde alınan kesitler. Yatay profil gibi düşünün.
- **Eksen 1 (Crossline):** Inline'a dik yönde alınan kesitler. Diğer yatay profil.
- **Eksen 2 (Derinlik):** Yüzeyden derine doğru olan eksen. 255 örnek = ~1275 metre.

Neden iki ayrı test seti var? Test1 inline yönünde, Test2 crossline yönündedir. Model sadece inline görüntüler üzerinde iyiye genellenebilir değil demektir. İkisinde de iyi olması gerekir — bu yüzden multi-view eğitim yapıyoruz.

2. Kesifci Veri Analizi (EDA)

Ne yapiliyor?

Modele gecmeden once verinin yapisi inceleniyor: sinif dagilimi, ornek kesitler ve etiket goruntuleri.

6 Fasiyes Sinifi

Sinif ID	Isim	Renk	Aciklama
S0	Upper North Sea (NS)	#3288bd (mavi)	En ust jeolojik katman
S1	Lower North Sea	#66c2a5 (yesil)	Ust NS'nin alti
S2	Rijnland	#abdda4 (acik yesil)	Orta katman
S3	Scruff	#e6f598 (sari)	Ince gecis katmani
S4	Zechstein	#fdae61 (turuncu)	Tuz tabakalari — az gorulur
S5	Under Zechstein	#f46d43 (kirmizi)	En dip — cok az gorulur

Sinif dengesizligi sorunu

S0 ve S1 volumun buyuk cogunlugunu olusturur. S4 (Zechstein) ve S5 (Under Zechstein) ise piksel bazinda cok kucuk bir kesiri olusturur. Bu durum sinif dengesizligi problemi yaratir: egitilmemis bir model sadece cok sayida S0/S1 tahmin ederek yuksek dogruluk elde edebilir, ama azinlik siniflari hic dogru tahmin edemez. Bu nedenle ileride WeightedRandomSampler ve Focal Loss kullanılacaktır.

3. Blok-Bazli Train/Val Split + Sinif Agirliklari

Spatial leakage'i onlemek icin cok onemli bir adim

Neden rastgele split yapmiyoruz?

Sismik veri uzaysal olarak sureklidir: birbirine komsu iki slice neredeyse ayni bilgiyi tasir. Eger rastgele split yapilsaydi, train setindeki 200. slice ile val setindeki 201. slice yan yana olurdu. Model esasen 'train slice'in komsu kopyasini' goruyor olurdu. Bu duruma **spatial leakage** denir ve modelin gercekte cok daha kotu oldugunu gizler.

Cozum: Blok-bazli split

Split Stratejisi

Train inline: [0, 320) — 401 inline'in ilk %80'i

Val inline: [320, 401) — son %20 inline blogu

Train xline: [0, 701) — tum crossline'lar train'de

Neden crossline val yok?: Test2 zaten crossline yonunde; crossline val olsaydi test ile cakisirdi

Focal alpha — sinif agirliklari nasil hesaplaniyor?

Her sinifin train volumundeki piksel frekansi hesaplanir. Sonra tersine cevirilir: seyrek sinif → buyuk agirlik. Bu agirliklar Focal Loss'a verilir ki nadir siniflar daha fazla ceza alsin.

```
class_freq = train_counts / train_counts.sum() # ornek: S4 -> 0.003
focal_alpha = 1.0 / (class_freq + 1e-8) # tersi: S4 -> ~333
focal_alpha = focal_alpha / focal_alpha.sum() # normalize: toplam = 1
```

4. 2.5D Dataset + Multi-View DataLoader

v7'nin en kritik yeniligi: 3 komsu slice = 3 kanal

2.5D (2.5 Boyutlu) fikri nedir?

Tam 3D konvolusyon kullanmak çok pahalidir (hafıza + hesaplama). Tam 2D kullanmak ise her slice'i birbirinden bağımsız isiler — derinlik sürekliliği kaybolur. 2.5D uzlaşmadır: her slice için **[önceki, simdiki, sonraki]** 3 komsu slice alınır ve bunlar RGB kanalları gibi 3 kanallı bir görüntü oluşturur.

Kanal	İçerik	Benzetme
Kanal 0 (R)	i-1. slice (önceki)	Gecmisten bilgi
Kanal 1 (G)	i. slice (şimdiki)	Asıl görüntü
Kanal 2 (B)	i+1. slice (sonraki)	Gelecekteki bilgi

ImageNet uyumu neden önemli?

EfficientNet-B4 3 kanallı (RGB) görüntüler üzerinde eğitilmiştir. 3 kanallı sismik input sayesinde ImageNet ağırlıklarını doğrudan kullanabiliyoruz. Bu, sıfırdan eğitim yerine güçlü özellikleri miras almanın yoludur.

Kenar durumu: hacmin ilk ve son slice'i

```
i_prev = max(0, i - 1) # 0. slice için önceki yine 0. slice
i_next = min(n_slices-1, i+1) # Son slice için sonraki yine son slice
```

Bu sayede IndexError olmaz. Kenar slice'larda bilgi tekrar eder ama bu kabul edilebilir çünkü kenar etkisi sınırlıdır.

axis parametresi — inline mi crossline mi?

```
# axis=0 -> inline slicing: vol[i] shape: (701, 255)
# axis=1 -> crossline slicing: vol[:, i] shape: (401, 255)
```

Aynı dataset sınıfı her iki yöne de hizmet eder. ConcatDataset ile inline + crossline dataset'leri birleştiriliyor; model her epoch'ta her iki yönden de görüntüleri işliyor.

Görüntü boyutu ve interpolasyon

Ham kesitler 701x255 veya 401x255 boyutundadır. v7'de bunlar **320x320**'ye resize ediliyor (v5/v6: 256x256). Görüntü için bilinear, maske için nearest-neighbor interpolasyonu kullanılıyor. Maskedeki etiketler tam sayı olduğundan bilinear interpolasyon uygulanamaz — ara değer üretmek yanlış etiket oluşturur.

Normalizasyon — neden sadece train istatistiki kullanılıyor?

```
train_mean = train_seismic.mean()
train_std = train_seismic.std() + 1e-8
# Test volumleri de AYNI train istatistiki ile normalize ediliyor!
```

Eğer test verisi kendi istatistiki ile normalize edilseydi bu **veri sızıntısı** olurdu. Gerçek hayatta test verisine bakma imkanınız olmaz. Bu nedenle test/val daima train istatistiki ile işlenir.

Augmentasyon stratejisi

Augmentasyon	Parametre	Neden?
--------------	-----------	--------

HorizontalFlip	p=0.5	Yatay simetri; jeoloji genellikle yatayda simetrik
ShiftScaleRotate	shift=0.1, scale=0.15, rotate=10, p=0.5	Pozisyon ve ölçek değişimi
ElasticTransform	alpha=80, sigma=10, p=0.3	Jeolojik katlarda doğal eğrilikler
GridDistortion	5 adım, distort=0.2, p=0.3	Ek geometrik bozulma
RandomBrightnessContrast	0.15, p=0.4	Amplitud varyasyonu
GaussNoise	std 0.001-0.015, p=0.3	Gerçek sismik gürültüsünü taklit et
CoarseDropout	6 delik, 20x20, p=0.2	Modeli eksik bilgiyle de çalışmaya zorla
VerticalFlip	YOK!	Derinlik eksenini ters çevirilmemeli — jeolojik anlam kaybolur

Polarity inversion (augment_polarity=True): %50 olasılıkla $img = -img$ yapılıyor. Sismik veride amplitudun işareti bazen arıksaldır; ters polarite de geçerli bir sismik görüntü olabilir.

4b. WeightedRandomSampler — Nadir Sinifli Slice'lara Oncelik

Sorun nedir?

Zechstein (S4) ve Under Zechstein (S5) sadece volumun belirli bir bolgesinde bulunur. Cok az sayida slice bu siniflara ait piksel icerir. Rastgele ornekleme yapilsaydi model bu slice'lari nadiren gorur ve bu siniflari ogrenmes.

Cozum: Agirlikli Ornekleme

```
RARE_CLASSES = [4, 5] # Zechstein ve Under Zechstein
RARE_BOOST = 10.0 # Bu siniflarin oldugu slice'lar 10x daha fazla secilsin

# Her slice icin agirlik hesapla:
rare_px = S4 + S5 piksel sayisi
w = 1.0 + (rare_px / toplam_piksel) * RARE_BOOST
```

Nadir sinif piksel yuzdesi yuksek olan slice'lar cok daha yuksek agirlik alir. WeightedRandomSampler bu agirliklarla replacement=True ile ornekleme yapar — yani ayni slice birden fazla kez bir epoch icinde gorulebilir.

DataLoader ayarlari

DataLoader Konfigurasyon

BATCH_SIZE: 6 (v6'dan dusuruldu, 320x320 cozunurluk nedeniyle VRAM doldu)

ACCUM_STEPS: 4 → efektif batch = 6 x 4 = 24

NUM_WORKERS: 0 (Windows) veya 2 (Linux/Mac) — paralel veri yukleme

pin_memory: True sadece CUDA'da — CPU→GPU transferi hizlandirir

sampler vs shuffle: sampler aktifken shuffle kapali olmalı (sampler ornekleme seklini belirler)

5. Model — DeepLabV3+ (EfficientNet-B4, in_channels=3)

DeepLabV3+ nedir?

Google tarafından geliştirilmiş bir semantik segmentasyon mimarisidir. İki ana bileşeni vardır: **Encoder** (görsel özellik çıkarıcı) ve **Decoder** (piksel bazlı sınıf haritası üreten).

Mimari bileşenler

Bileşen	Görevi	v7 Seçimi
Encoder	Görüntüden hiyerarşik özellikler çıkar	EfficientNet-B4 (ImageNet pretrained)
ASPP	Farklı ölçeklerde bağlamsal bilgi toplar	Rates=(12, 24, 36)
Decoder	Düşük çözünürlüklü özellikleri birleştirir ve upsample eder	SMP default decoder
Çıkış katmanı	Her piksel için 6 sınıf skoru üretir	6 kanal (NUM_CLASSES)

EfficientNet-B4 neden seçildi?

EfficientNet ailesi, doğruluk ve parametre sayısı arasındaki dengeyi optimize etmek üzere NAS (Neural Architecture Search) ile tasarlanmıştır. B4 versiyonu, B0'dan daha büyük ama ResNet-50'den daha verimlidir. Özellikle sınırlı VRAM'da yüksek çözünürlüklü segmentasyon için iyi bir seçimdir. ImageNet pretraining sayesinde kenar, doku, şekil gibi genel görsel özellikleri zaten biliyor; biz sadece jeolojik alana ince ayar yapıyoruz.

ASPP (Atrous Spatial Pyramid Pooling) nedir?

Klasik konvolüsyon sabit bir alanı tarar. Jeolojik katmanlar ise hem çok ince hem de çok kalın olabilir. ASPP, farklı **dilation (atrous) oranlarıyla** aynı görüntü üzerinde farklı büyüklüklerden bilgi toplar ve bunları birleştirir.

Rate	Efektif Alan	Ne yakalanır?
12	Küçük	İnce katmanlar, keskin sınırlar
24	Orta	Orta kalınlıktaki jeolojik birimler
36	Büyük	Geniş fasiyes bölgeleri, global bağlam

encoder_output_stride=16 ne demek?

Encoder'ın çıktısı, girdi çözünürlüğüne göre 1/16 oranında küçültülmüştür. 320x320 girdi → 20x20 encoder çıktısı. Küçük stride daha yüksek çözünürlük demektir ama daha fazla VRAM gerekir. 16, kalite ve bellek arasında iyi bir denge noktasıdır.

activation=None neden?

Model ham logit (ham skor) üretir, aktivasyon uygulamaz. Çünkü kayıp fonksiyonlarımız (cross-entropy, focal) logit beklentisindedir. Eğer burada sigmoid/softmax uygulansaydı kayıp hesabı iki kez aktivasyon uygulayacaktı ve hatalı olacaktı.

6. Kayip Fonksiyonu: $0.4 \cdot \text{LS-CE} + 0.3 \cdot \text{Dice} + 0.3 \cdot \text{Focal}$

Neden uc farkli loss birlestiriyoruz?

Her loss fonksiyonu farkli bir problemi ele aliyor. Hicbiri tek basina yeterli degil:

Loss	Agirlik	Ne icin iyi?	Eksigi
Label Smoothing CE	0.4	Genel sinif ayirimi, kalibrasyonu iyilestirir	Sinif dengesizligine koy duyarsiz
Dice Loss	0.3	Bolge cakismasi optimize eder; dengesizlige dayanikli	Buyuk siniflar kucuklere baskin cikabilir
Focal Loss	0.3	Zor ornekler ve azinlik siniflara odaklanir	Hyperparametre duyarli (gamma)

Label Smoothing nedir?

Klasik cross-entropy kayip fonksiyonu, dogru sinif icin tam 1.0, diger siniflar icin 0.0 hedefler. Bu model'in cok emin olmasina yol acar — **overconfidence** sorunu. Label smoothing (eps=0.1) dogruyu 0.9167 (1 - 0.1 + 0.1/6), yanlisleri 0.0167 (0.1/6) hedefler. Model daha kalibrasyonlu tahmin uretir.

Focal Loss — gamma=2 ne anlama gelir?

```
focal_loss = alpha_t * (1 - pt)^gamma * CE
# pt = modelin dogru sinif icin tahmin ettigi olasilik
# (1-pt)^2 terimi: pt yuksekse (kolay ornekler) loss kuculuyor
# pt dusukse (zor ornekler/azinlik sinif) loss oldugundan buyuk kaliyor
```

gamma=2: Kolay ornekler (pt > 0.8) icin loss ~%4'e dusuyor. Zor ornekler (pt < 0.3) tam agirligıyla hesaplaniyor. Boylece model zamanini zaten cozulmus orneklerle harcamiyor.

Dice Loss — bolge cakismasi metrigini optimize eder

```
# Her sinif c icin:
intersection = sum(predicted_c * true_c)
dice_c = (2 * intersection + smooth) / (pred_c.sum() + true_c.sum() + smooth)
loss = 1 - mean(dice_c for all c)
```

smooth=1.0 (Laplace smoothing): Paydanin sifira bolunmesini onler. Eger bir sinif hi?? yoksa dice=1/(0+0+1)=1 olur ve modeli cezalandirmaz.

Mixup Augmentation (v7 yeniligi)

Her batch'te %50 olasilikla iki rastgele ornek karistirilir:

```
lam = Beta(0.2, 0.2) ornegi # genellikle 0.0 veya 1.0'a yakin
mixed_x = lam * x + (1-lam) * x[shuffled]
loss = lam * criterion(pred, y_a) + (1-lam) * criterion(pred, y_b)
```

Mixup, modeli daha generalize olmaya zorlar. Iki sinif sinirinda kalan pikseller her iki sinifi da birden optimize eder. alpha=0.2 ile lam cogunlukla 0.0-0.2 veya 0.8-1.0 araligindadir — tam karisim nadirdir.

Optimizer ve Scheduler

AdamW + CosineAnnealingWarmRestarts

AdamW: Adam optimizer + ayrı weight decay (L2 regularizasyon ağırlık güncellenmesine dahil değil)

lr=1e-4: Başlangıç öğrenme hızı

weight_decay=1e-3: Ağırlıkları sıfıra çekme gücü; overfitting'i azaltır

T_0=25: İlk cosine dalgası 25 epoch sürüyor

T_mult=1: Her restart sonrası T aynı kalıyor (25 epoch)

eta_min=1e-6: Cosine'in en dip noktası — sıfıra düşmemesi için alt sınır

CosineWarmRestarts: 25 epochluk periyotlarla lr, maksimumdan minimuma cosine eğrisiyle düşüyor. Her 25 epochta lr tekrar maksimuma donuyor (restart). Bu sayede model farklı öğrenme hızlarını deniyor ve farklı lokal optimumları keşfiyor.

7. Metrik Fonksiyonlari

Hangi metrikler kullaniliyor ve neden?

Metrik	Formul	Ne olcuyor?	Sinif dengesizligine duyarli?
PA (Pixel Accuracy)	dogru piksel / toplam piksel	Genel isabetlilik	EVET — cok yaniltic olabilir
MCA (Mean Class Acc)	sinif acc ortalamasi	Sinif bazli dogruluk	Hayir
mIoU	IoU'larin sinif ortalamasi	ASIL METRIK — kesisim/birlenim	Hayir
Mean Dice	Dice'larin ortalamasi	mIoU ile benzer ama daha yumusak	Hayir

IoU (Intersection over Union) nasıl hesaplanıyor?

```
# Confusion matrix'ten:
inter = cm[c, c] # Dogru pozitif (TP)
union = cm[c,:].sum() # Gercekte c olan pikseller (TP + FN)
+ cm[:,c].sum() # Tahmin edilen c olan pikseller (TP + FP)
- inter # TP iki kez sayildi, bir kere cikart
iou_c = inter / (union + 1e-8)
```

IoU=1 mukemmel, IoU=0 hic cakisma yok. mIoU tum siniflarin IoU'sunu esit agirlikla ortalar. Bu nedenle S4 ve S5 gibileri kotu tahmin edilirse mIoU duser — sinif dengesizligini gizlemez.

Confusion matrix neden önemli?

Hangi sinifin hangisiyle karistirildigini gosteriyor. Ornegin S3 (Scruff) coklukla S2 (Rijnland) ile karisabilir — bunlar komsu katmanlar. Bu bilgi veri toplama veya mimari iyilestirmesi icin yol gosterir.

8. Egitim Dongusu — 100 Epoch + Grad Accumulation + Early Stop

Genel akis

Adim	Ne yapiliyor?
1. Checkpoint kontrol	Daha once egitim yapilmis mi? Varsa kaldigi yerden devam et
2. Train dongusu	Her batch icin ileri+geri + gradient accumulation
3. Mixup karari	%50 olasilikla batch karistiriliyor
4. AMP (autocast)	float16 ile hesapla, float32'de agirlik guncelle
5. Grad clip	max_norm=1.0 ile gradyanlar kirpiliyor
6. Optimizer.step	Her 4 adimda bir agirlik guncelleniyor
7. Validation	model.eval() modunda, augmentasyon yok
8. Checkpoint kaydet	Her epoch sonunda .pth dosyasina yaz
9. Best model kaydet	mIoU iyilesirse ayri best.pth dosyasi
10. Early stopping	25 epoch boyunca iyilesme yoksa dur

Gradient Accumulation neden gerekli?

320x320 cozunurluk + EfficientNet-B4 + 3 kanal = buyuk VRAM talebi. Batch size 6'ya indirildi. Ama kucuk batch'ler gurutulu gradient uretiyor. Cozum: 4 batch biriktir, sonra guncelle. Efektif batch = $6 \times 4 = 24$.

```
loss = criterion(preds, masks) / ACCUM_STEPS # Olcekle  
loss.backward() # Gradient biriktir  
if (step+1) % ACCUM_STEPS == 0: # Her 4 adimda:  
    optimizer.step() # Guncelle  
    optimizer.zero_grad() # Sifirla
```

Automatic Mixed Precision (AMP) nedir?

CUDA'da float32 yerine float16 ile hesaplama yaparak hem bellek hem de hiz kazaniliyor. GradScaler gradyanlari float16'da sifira donmesini (underflow) onler.

```
with torch.amp.autocast("cuda"): # Bu blokta float16 kullan  
    preds = model(imgs)  
    loss = criterion(preds, masks)  
    scaler.scale(loss).backward() # Olcekli geri yayilim  
    scaler.unscale_(optimizer) # Gercek gradyanlara don  
    torch.nn.utils.clip_grad_norm(..., 1.0) # Kript  
    scaler.step(optimizer) # Guncelle  
    scaler.update() # Scale faktorunu ayarla
```

Gradient Clipping (max_norm=1.0) neden?

Bazi durumlarda gradyanlar cok buyuyebilir — **gradient explosion**. max_norm=1.0 tum gradyanlari L2 normunun 1.0'i gecmesini engeller. Bu ozellikle derin modellerde ve bircok loss bileşeni varken stabilitesi saglar.

Checkpoint sistemi

Her epoch sonunda model, optimizer, scheduler, gecmis ve patience sayaci kaydediliyor. Egitim herhangi bir nedenle kesilirse (Kaggle timeout, sistem kapanmasi) ayni hucre tekrar calistirildiginda kaldigi yerden devam eder.

9. Test Zamani Augmentasyonu (TTA)

TTA ne yapıyor?

Her test görüntüsünü 3 farklı biçimde modele verip olasılıklarının ortalamasını alıyoruz. Bu bedava +1-3% mIoU kazandırıyor çünkü model tek bakış açısına karşı overfitting'e daha az maruz kalıyor.

TTA Adımı	Ne yapılır?	Neden?
Original	Görüntü olduğu gibi	Temel tahmin
HFlip	Görüntü yatay çevrilir, tahmin yapılır, tekrar çevrilir	Yatay simetri kazanılır
Polarity inversion	img = -img ile polarite tersine çevrilir, tahmin yapılır	Sismik polarite varyasyonu

```
probs = softmax(model(img)) # Orijinal
probs += softmax(flip(model(flip(img)))) # HFlip
probs += softmax(model(-img)) # Polarity
probs /= 3.0 # Ortalama
```

Dikkat: HFlip sonrası tahmin de flip'leniyor. Aksi takdirde koordinatlar uyusmaz ve sonuç anlamsız olur.

10-13. Gorsellestirme ve Versiyon Karsilastirma

Egitim egrileri (Bolum 10)

3 grafik: Loss (train vs val), Metrikler (mIoU ve Dice), Learning Rate. Train loss dusup val loss artiyorsa overfitting var. mIoU plato yapmissa early stopping devreye girmeli. LR grafigi cosine restart dongulerini gosteriyor.

Segmentasyon karsilastirmasi (Bolum 11)

6 satir (3 inline + 3 crossline), 3 sutun: Sismik goruntu | Gercek fasiyes | Model tahmini. img[1] gosteriliyor — yani 3 kanalli input'un ortasi (simdiki slice). Bu gorsel kalitatif degerlendirme icin kritik.

Confusion Matrix (Bolum 12)

Sol: Ham piksel sayilari. Sag: Satir bazli normalize edilmis (her sinif toplamina gore). Normalize matris daha yorumlanabilirdir: kose hucreleri yuksekse model iyi.

Per-class IoU / Dice (Bolum 13)

Her sinif icin ayri IoU ve Dice bar grafigi. Yatay kesikli cizgiler overall mIoU ve mDice. S4 ve S5 genellikle dusuk cikacaktır — WeightedSampler'in etkisi buradan olculebilir.

Versiyon karsilastirmasi (Bolum 14)

v3, v5 ve v7 sonuclari yan yana tablo halinde gosteriliyor. v5 metrikleri diskteyse JSON'dan, yoksa sabit degerler kullaniliyor. Bu tablo makalede 'Ablation Study' veya 'Comparison Table' olarak yer alabilir.

Tum Pipeline Ozeti

Adim	Teknik	Neden?
Veri	F3 Block, NPY format, 3D volume	Acik kaynak gercek sismik veri
Split	Blok-bazli %80/%20	Spatial leakage engellemek icin
Normalizasyon	Train mean/std ile Z-score	Veri sizintisini onle
Input	2.5D — 3 komsu slice → 3 kanal	Derinlik surekliligini yakala, ImageNet uyumu
Cozunurluk	320x320 (v7 yeniligi)	Daha fazla spatial detay
Augmentasyon	7 teknik + polarity flip	Overfitting'e karsi
Ornekleme	WeightedRandomSampler (10x boost)	Nadir siniflara odaklan
Model	DeepLabV3+ EfficientNet-B4	ASPP ile cok-olcekli segmentasyon
Loss	0.4 LS-CE + 0.3 Dice + 0.3 Focal	Dengesiz siniflar icin triple loss
Mixup	alpha=0.2, p=0.5 (v7 yeniligi)	Regularizasyon guclendir
Optimizer	AdamW + CosineWarmRestarts	Stabil egitim + periyodik restart

Grad Accum	4 adim = efektif batch 24	VRAM kisitinda buyuk batch efekti
AMP	float16 (CUDA'da)	VRAM ve hiz kazanimi
Grad Clip	max_norm=1.0	Gradient explosion onle
Early Stop	patience=25 epoch	Fazla egitimi engelle
Checkpoint	Her epoch kayit	Kesintisiz egitim
TTA	HFlip + Polarity, 3x tahmin	Bedavaya +1-3% mIoU
Metrik	mIoU (birincil), Dice, PA, MCA	Sinif dengesizligini gizlemeyen metrik