

Yedek Slaytlar (Q&A)

15 slayt — soru gelirse açılır, ana sunumda yer almaz.

Her slaytın başında [hangi soruda kullanılır] etiketi var.

YS-1 [S1, S2] — Methodology fix kod detayı

Yol A: 3 satırlık fix

```
# cell-9 (split)
val_inline_idx = np.arange(160, 240)
BUFFER = 2
train_inline_idx = np.concatenate([
    np.arange(0, 160 - BUFFER),
    np.arange(240 + BUFFER, 401),
])

# cell-11 (Dataset)
def __getitem__(self, idx):
    if self.axis == 1: # crossline
        img = volume[:, idx, :]
        # train_inline_mask: val piksellerini çıkar
        img = img[self.train_inline_mask]
    ...
```

Ek karmaşıklık: ~5 satır. Etki: 3 sızıntı tamamen kapatıldı.

YS-2 [S3] — v3 → v9 tam evrim

Sürüm	Combined mIoU	Anahtar değişiklik
v3 (U-Net)	0.4012	Plain U-Net baseline
v5	0.7582	+ EffNet-B4 + DeepLabV3+ + 320
v6	0.7580	+ 2.5D + WeightedSampler
v7-broken	0.7926	(leakage'lı yapay artış)
v7-fixed	0.7668	+ Yol A methodology fix
v7-c4fix	0.7779	+ 5-ch + Lovász + xline-aware aug
v9 (single-seed)	0.7769	+ 384×384 + multi-scale TTA
v9 ensemble	0.7910 ± 0.006	+ 3-seed softmax averaging

Net ilerleme: v3 → v9 ensemble = +39 puan mIoU.

YS-3 [S4] — Liu 2020 detayı (3D neden değil)

Liu et al. 2020, Geophysics 10.1190/geo2019-0467.1:

"On the F3 facies dataset, section-based 2D models consistently outperform patch-based 3D approaches due to limited training volume."

Pratik nedenler:

- F3 = **tek 3D volüm** → 3D patch-based zorunlu → global jeolojik bağlam parçalanır
- Sismik için **3D pretrained encoder yok** (Med3D tıbbi, transfer kanıtlanmadı)
- VRAM patlaması: 16-24 GB+ gerekir, bizim 3060 Ti 8 GB

Bizim 2.5D = ImageNet uyumlu, VRAM-dostu, jeolojik bağlam korunur.

YS-4 [S5] — Sınırlı ablation tablo (tek-seed, SEED=42)

Konfig	Combined mIoU	Δ vs v9	Class 4 Test2	Δ C4	Yorum
v9 (full pipeline)	0.7769	—	0.2304	—	baseline
– Lovász (Triple loss)	0.7792	+0.23p	0.2161	–1.43p	Lovász Class 4 minörlüğüne katkı
– 5-ch (3-ch 2.5D, ± 1)	0.7714	–0.55p	0.1199	–11.05p ⚠	2.5D context Zechstein için kritik
– xline-aware aug	0.7688	–0.81p	0.1316	–9.88p ⚠	xline aug C4+Test2 için kritik
– TTA varyantları	—	—	—	—	(tezin uzun versiyonunda)
– Mixup / Focal alpha	—	—	—	—	(tezin uzun versiyonunda)

Hikâye: 5-channel 2.5D + xline-aware aug, Class 4 Test2 için **olmazsa olmaz** — her birinin OFF konfigi ~ -10 puan etki yaratıyor. Lovász Combined'a değil, **doğrudan minör sınıfa** katkı sağlıyor.

Tek-seed ablation (SEED=42). Multi-seed varyans Class 4 için $\pm 4p$ std — bulgular ana çizgi göstergesidir.

YS-5 [S6] — Class 4 hata mode analizi (Test2)

Class 4 GT piksellerinin hangi sınıfa atandığı:

Atanan Sınıf	Yüzde
C4 Zechstein (doğru)	%26
C5 Under Zechstein (komşu alt)	%59
C3 Scruff (komşu üst)	%12
Diğer	%3

Yorum: Model Zechstein'i **tamamen kaybetmiyor**, sınırını yanlış çiziyor. Anisotropic morfoloji (inline blok ↔ xline diapir) genelleme zafiyeti.

→ Bu, mimari sorun değil **alan adaptasyonu** problemi.

YS-6 [S7] — Tam SOTA literatür tablosu

Yöntem	Yıl	Sayı	Split	Karşılaştırılabilir?
Alaudah section + aug + skip	2019	FwIoU 0.832, PA 0.905, MCA 0.817	Geographic	✓ Benchmark referansı
Liu et al. (3D CNN + GAN)	2020	Paywall, sayı yok	Geographic	⚠
Wiley/Hindawi ensemble	2022	mIoU 0.9392	Random patch, 7 sınıf	✗
CONSS semi-sup	2023	mIoU 0.9462	Kendi split	✗
AdaSemSeg target-only	2025	FwIoU 0.86	Farklı F3 split	⚠
UmixClick interactive	2025	mIoU 0.7666, PA 0.9351	Belirsiz	✗ Interactive
v9 ensemble (bizim)	2026	mIoU 0.7910 ± 0.006, PA 0.940, MCA 0.873	Alaudah geographic	✓

Detay: docs/literature_table.md

YS-7 [S8] — K-fold CV maliyet analizi

5-fold CV, v9 mimarisi için:

Fold	Eğitim süresi	GPU saat
Fold 1	~8 saat	8
Fold 2	~8 saat	8
Fold 3	~8 saat	8
Fold 4	~8 saat	8
Fold 5	~8 saat	8
Toplam	~40 saat	40

Multi-seed (3 seed) maliyeti: ~24 saat. Multi-seed varyans ölçümünde benzer rol oynar, **maliyet 1.7x daha düşük.**

Sonuç: Yüksek lisans semineri için multi-seed pragmatik seçim. Tezin uzun versiyonunda K-fold planlanıyor.

YS-8 [S9, S11] — SFM tam deneysel kurulum

SFM v1 (Sheng 2024 base):

- Backbone: **ViT-B/16**, MAE pretrained on 2.3M sismik slice
- Input: 5-ch 2.5D → 1-ch projection (Sheng'in beklediği format)
- Head: MLAHead (multi-layer aggregation)
- Encoder lr: **5e-5** (frozen-ish), decoder lr: 1e-3
- Sonuç: Combined 0.7281, **Class 4 Test2 = 0.270** ← lider

SFM v2 (agresif fine-tune):

- Encoder lr: **2e-4** + layer-wise lr decay 0.9
- WeightedRandomSampler rare classes ×15
- Sonuç: Combined 0.7677, **best val 0.823** ← lider, ama Class 4 Test2 0.20'ye düştü

Ders: Encoder agresif fine-tune Test1'i iyileştirir, Test2 genellemesini bozar. Trade-off.

YS-9 [S10] — v9 vs v7-c4fix per-class breakdown

Sınıf	v7-c4fix	v9 (single)	v9 ensemble	Δ ensemble
C0 Upper NS	0.943	0.947	0.951	+0.008
C1 Lower NS	0.791	0.797	0.812	+0.021
C2 Rijnland	0.927	0.936	0.941	+0.014
C3 Scruff	0.621	0.601	0.629	+0.008
C4 Zechstein	0.789	0.784	0.803	+0.014
C5 Under Zech	0.588	0.601	0.609	+0.021

Ensemble net katkısı: her sınıfta +0.01–0.02p. C5'te %3.5p iyileşme — küçük sınıflar ensemble'dan en çok faydalaniyor.

YS-10 [S13] — 3-seed std her sınıf için

Sınıf (Combined)	Mean IoU	Std	CV (std/mean)
C0 Upper NS	0.947	0.005	0.5%
C1 Lower NS	0.808	0.010	1.2%
C2 Rijnland	0.938	0.004	0.4%
C3 Scruff	0.625	0.028	4.5%
C4 Zechstein	0.797	0.013	1.7%
C5 Under Zech	0.603	0.018	3.0%

Class 4 Test2 detayı: 0.230 / 0.156 / 0.163 → mean 0.183, **std 0.041** (CV %22 — yüksek!)

→ Class 4 Test2'de seed varyansı, modelin instabilitesinin somut göstergesi.

YS-11 [S12] — Resize evaluator etki tahmini

Eval çözünürlüğünün metriklere etkisi (deneysel tahmin):

Metrik	Resize hassasiyeti	Tahmini fark (384 vs orijinal)
Pixel Accuracy	Düşük	± 0.5 puan
Mean Class Acc	Düşük	± 1.0 puan
mIoU / FwIoU	Yüksek	$\pm 2-4$ puan (öngörülmesi zor)

Sebep: Resize sırasında **küçük sınıfların sınır pikselleri yumuşatılır** — IoU'da büyük etki, accuracy'de küçük.

Beklenti: Orijinal-resolution evaluator yapıldığında mIoU bir miktar **düşebilir** (resize sınır pikselleri görmezden geliyor).
Bunu da dürüstçe söylüyoruz.

YS-12 [S14] — AMP + Lovász FP32 wrap kod

```
from torch.cuda.amp import autocast

with autocast(): # global fp16 context
    logits = model(x)                # fp16
    loss_ce = ls_ce(logits, y)        # fp16
    loss_dice = dice(logits, y)        # fp16
    loss_focal = focal(logits, y)      # fp16

    with autocast(enabled=False):      # FP32 wrap
        logits_fp32 = logits.float()
        loss_lov = lovasz_softmax(logits_fp32, y)

    total = 0.30 * loss_ce + 0.25 * loss_dice \
            + 0.25 * loss_focal + 0.20 * loss_lov

scaler.scale(total).backward()
```

Standart PyTorch pattern — `autocast(enabled=False)` ile precision karıştırma. NaN sorunu çözüldü, gradient scaler bozulmadı.

YS-13 [misc] — Hyperparameter tablosu

Parametre	Değer	Notlar
Optimizer	AdamW	$\beta_1=0.9$, $\beta_2=0.999$
Learning rate	1e-4	base lr
Weight decay	1e-3	
Scheduler	CosineAnnealingWarmRestarts	$T_0=25$, $\eta_{\min}=1e-6$
Batch size	4	gradient accum=6 $\rightarrow$ eff. batch 24
Epochs	100	early stopping patience=25
Image size	384 $\times$ 384	
Loss weights	0.30/0.25/0.25/0.20	LS-CE/Dice/Focal/Lovász
Focal γ	2.0	
LS ϵ	0.1	
Mixup α	0.2	$p=0.5$
Sampler boost	C4/C5 $\times 10$	WeightedRandomSampler

Donanım: RTX 3060 Ti (8 GB VRAM), AMP, gradient accum.

YS-14 [misc] — VerticalFlip neden yok

Sismikte derinlik eksenini jeofiziksel olarak ters çevrilemez:

- Yer çekimi → üst tabakalar üstte (genç sedimanlar), alt tabakalar altta (yaşlı)
- VerticalFlip → "yaşlı kayalar üstte" gibi imkansız bir konfigürasyon üretir
- Model bu yanlış görüntüler üzerinde eğitilirse stratigrafik sıralamayı bozar

Bizim aug listesi:

-  HorizontalFlip (yatay simetri jeolojik olarak geçerli)
-  ShiftScaleRotate (küçük açı)
-  ElasticTransform, GridDistortion (xline-aware)
-  Polarity inversion (sismik sinyal $\times -1$, ters reflektörler)
-  **VerticalFlip** (jeolojik kural ihlali)

YS-15 [Future Work] — Heterojen ensemble deney planı

Hipotez: v9 + SFM v1 softmax averaging → en iyisi.

Model	Combined	C4 Test2	Hangi konuda iyi
v9 ensemble	0.791	0.183	Genel performans
SFM v1	0.728	0.270	Class 4 morfoloji
Heterojen ensemble (öngörü)	~0.79	~0.24-0.27	İkisinin gücü

Yöntem:

1. v9 ensemble softmax çıktısı (mevcut)
2. SFM v1 softmax çıktısı (mevcut)
3. Ağırlıklı ortalama: $0.5 \cdot \text{softmax_v9} + 0.5 \cdot \text{softmax_sfm}$ (veya öğrenilebilir w)
4. argmax → final tahmin

Maliyet: Sadece inference, ~30 dk GPU. **Yüksek değer / düşük maliyet** future work.

Yedek Slaytlar Bitti

Ana sunuma dönmek için **Esc** veya slayt 1.

Hatırlatma: Her yedek slaydın başındaki `[Sx]` etiketi, hangi soru için olduğunu gösterir. Provada ezberle.