

Sismik Fasiyes Sınıflandırması için Metodoloji-Sağlam DeepLabV3+ Yaklaşımı: F3 Hollanda Veri Kümesinde Çoklu-Tohum Topluluk ve Sınıf-Odaklı Hata Analizi

Mehmet Kişli

Bilgisayar Mühendisliği Yüksek Lisans Programı

Bilgisayarda Görme Dersi — Seminer Çalışması

E-posta: mehmettkisli@gmail.com

Özet—Sismik fasiyes sınıflandırması, yeraltı tabakalarının jeolojik birimlere ayrılması açısından hidrokarbon arama ve rezervuar karakterizasyonunda kritik öneme sahiptir. Bu çalışmada, Alaudah 2019 F3 Hollanda kıyaaltı bloğu kıyaslama veri kümesi üzerinde, 6 sınıflı semantik fasiyes segmentasyonu problemine yönelik metodoloji-sağlam bir DeepLabV3+ yaklaşımı sunulmaktadır. Önerilen sistem; ImageNet ön-eğitilmiş EfficientNet-B4 omurgası, 5 kanallı 2.5D girdi temsili (komşu kesit yığılma), QuadrupleLoss (etiket-yumuşatmalı çapraz-entropi + Dice + Focal + Lovász-Softmax) bileşeni, crossline-uyarlı veri artırma ve çok-ölçekli test-zamanı artırma (TTA) bileşenlerinden oluşmaktadır. Eğitim/doğrulama bölünmesinde tespit edilen üç kritik veri sızıntısı (bitişik blok doğrulama, crossline eksen boyu 3B sızıntı, 2.5D komşuluk sızıntısı) ortadan kaldırılarak *Yol A* adı verilen düzeltme uygulanmıştır. 3 bağımsız rastgele tohumla bağımsız olarak eğitilen modellerin softmaks ortalamasıyla elde edilen çoklu-tohum topluluk modeli; Birleşik mIoU = 0.791 ± 0.006 , piksel doğruluğu (PA) = 0.940, sınıf ortalaması doğruluğu (MCA) = 0.873, frekans-ağırlıklı IoU (FwIoU) = 0.892 ve Test1 mIoU = 0.804 değerlerini elde etmiştir. PA, MCA ve FwIoU metriklerinde Alaudah 2019 en iyi temel modelinin (PA 0.905, MCA 0.817, FwIoU 0.832) sırasıyla +3.5, +5.6 ve +5.9 puan üzerinde sonuç alınmıştır. Önemli bir akademik bulgu olarak, tek-tohumlu çalışmanın Class 4 (Zechstein) Test2 IoU sonucunun (0.230) istatistiksel bir aykırı değer olduğu tespit edilmiş; çoklu-tohum gerçek değer 0.183 ± 0.04 olarak raporlanmıştır. Sonuçlar, sismik segmentasyon problemlerinde tek-tohum rapor edilmesinin metodolojik risklerini ve coğrafi-bölünmeli değerlendirmenin önemini ortaya koymaktadır.

Index Terms—Sismik fasiyes sınıflandırması, semantik segmentasyon, DeepLabV3+, EfficientNet, F3 Hollanda, 2.5D girdi, Lovász-Softmax, çoklu-tohum topluluk, veri sızıntısı.

I. GİRİŞ

Sismik fasiyes sınıflandırması; yansıtıcılık, frekans içeriği ve geometrik morfoloji gibi özelliklere dayalı olarak yeraltı sismik kesitlerinde her pikseli ayrı bir jeolojik birime (örn. kumtaşı, kireçtaşı, tuz, şeyl) atayan piksel-bazlı bir semantik segmentasyon görevidir [1]. Endüstride bu görev

hâlâ büyük ölçüde uzman jeofizikçilerin manuel yorumlamalarıyla yürütülmekte; yorumcular arasında tutarsızlık, zaman maliyeti ve 3B hacimler için ölçeklenebilirlik sorunları doğmaktadır.

Derin öğrenmenin sismik veriler üzerinde yaygınlaşması, bu süreci hem hızlandırma hem de yorumcudan bağımsız tutarlı çıktılar sağlama potansiyeli taşımaktadır. Bununla birlikte, F3 Hollanda kıyaaltı bloğu üzerinde tutarlı ve adil karşılaştırılabilir sonuçlar üreten çalışmalar literatürde sınırlıdır: birçok yayın kendi rastgele yama (*patch*) bölünmesini kullanır [11], [12] ve coğrafi bölünme ile tutarlı olmayan, gerçekçi olmayan derecede yüksek metrikler bildirir. Alaudah ve arkadaşları [1] tarafından önerilen coğrafi (Test1: NW, Test2: E) bölünme, model genellenabilirliğini ve crossline yönündeki davranışı dürüst biçimde sınamak için literatürün önerilen birincil kıyaslama protokolüdür.

Bu çalışma şu katkıları sunmaktadır:

- 1) **Metodoloji-sağlam temel modeli (v9)**. DeepLabV3+ ve EfficientNet-B4 üzerine, 5 kanallı 2.5D girdi, QuadrupleLoss, crossline-uyarlı veri artırma ve çok-ölçekli TTA içeren bir mimari sunuyoruz. Tüm sürüm gelişimi (v3→v9) izlenebilir ve her aşamada metrik karşılaştırması yapılmıştır.
- 2) **Üç ayrı veri sızıntısının teşhisi ve düzeltilmesi**. Eğitim/doğrulama bölünmesinde (i) bitişik son-blok doğrulama, (ii) crossline eksen boyu 3B sızıntı, (iii) 2.5D komşu kesit sızıntısı olmak üzere üç ayrı sızıntı tespit edip *Yol A* adıyla bütünleşik bir düzeltme önerdik. Düzeltme öncesi ve sonrası metrikleri raporlanmaktadır.
- 3) **Çoklu-tohum topluluk ve varyans analizi**. 3 bağımsız tohumla (42, 43, 44) eğitilen modellerin softmaks ortalaması alınarak Birleşik mIoU = 0.791 ± 0.006 , PA = 0.940, MCA = 0.873 ve Test1 mIoU = 0.804 değerleri elde edilmiştir. PA ve MCA metriklerinde Alaudah baseline'ı sırasıyla +3.5 ve +5.6 puan üzerinde sonuç alınmıştır. Tek-tohumlu rapor edilen Class 4 (Zechstein) Test2 IoU sonucu (0.230) istatistiksel aykırı değer olarak tanımlanmış; gerçek

beklenen deęer 0.183 ± 0.04 olarak ölçülmüştür. Bu bulgu, sismik segmentasyonda tek-tohum raporlanmasının dürüstlük açısından yetersiz olduğunu açıkça göstermektedir.

- 4) **Bilinen sınırlılıkların açıkça ifade edilmesi.** Deęerlendirme protokolünde 384×384 yeniden örneklenmiş uzayda hesaplama yapıldığı, orijinal çözünürlüklü deęerlendiricinin bekleyen iş olduğu, AMP+Lovász NaN sorununun FP32 sarmalayıcı ile çözüldüğü gibi metodolojik nüanslar dürüstçe raporlanmaktadır.

II. İLGİLİ ÇALIŞMALAR

A. F3 Kıyaslaması ve Bilinen Sayılar

Alaudah ve arkadaşları [1] F3 hacmini coęrafi olarak Test1 (NW, daha homojen bölge) ve Test2 (D, büyük Zechstein diapiri içeren bölge) olarak ikiye ayırarak bir kıyaslama protokolü tanımlamıştır. Bu çalışmada raporlanan en güçlü temel model (*section + augmentation + skip connection*) şu deęerleri bildirmektedir: piksel doğruluęu (PA) 0.905, sınıf ortalaması doğruluęu (MCA) 0.817, frekans-ağırlıklı IoU (FwIoU) 0.832. Alaudah çalışması doğrudan mIoU rapor etmedięi için, sonraki çalışmaların mIoU sayılarıyla birebir karşılaştırma çoęu zaman geçer-sizdir.

Daha sonraki çalışmalar farklı bölünmeler kullanma eğilimindedir: Abid ve arkadaşları [11] rastgele 60/20/20 yama bölünmesi ile mIoU 0.939, CONSS yarı-denetimli yaklaşım [12] kendi düzeniyle mIoU 0.946 rapor eder. Bu sayılar coęrafi bölünme ile karşılaştırılamaz; çoęu zaman komşu yamalar arasında piksel düzeyinde sızıntı bulunmaktadır.

AdaSemSeg [13] az-örnekle (5-shot) F3 inline FwIoU 0.81 ve Baseline-1 (yalnız hedef-veri) ile FwIoU 0.86 bildirmiştir; ancak F3 bölünmesi farklıdır. Sheng ve arkadaşları [14] Sismik Temel Modeli (SFM) sunmuş; orijinal yayında F3 fasiyes için Alaudah protokolüyle uyumlu sayı raporlanmamış (testler Parihaka veri kümesi üzerinde yapılmıştır). Bu boşluğu doldurmak amacıyla, bu çalışmada SFM ViT-B/16 ön-eęitimli enkoderi F3 üzerinde *Alaudah coęrafi bölünmesi* ile ince-ayar edilmiş; hem dondurulmuş hem tam fine-tune varyantları için sonuçlar raporlanmıştır (Bölüm V-I). Yapılan literatür taramasında SFM'in F3 fasiyes veri kümesi üzerinde Alaudah coęrafi bölünme protokolüyle fine-tune sonuçlarına rastlanmamıştır; bu çalışma söz konusu boşluğu hedeflemektedir. Sistematiik bir öncelik iddiası için daha kapsamlı bir literatür taraması gerekmektedir.

B. 2.5D ve 3B Yaklaşımlar

3B konvolüsyonel sinir aęları (örn. V-Net) sismik volüm bağlamını koruma vaadinde bulunsalar da, tek bir eğitim volümü ile ön-eęitilmiş 3B sismik omurga olmaması ve yama-bazlı eğitimin global jeolojik bağlamı parçalaması nedeniyle pratikte sınırlı kalmaktadır [9]. 2.5D girdi (komşu k kesitin kanal eksenine yığılması) ImageNet ön-eęitimli

Tablo I
F3 VERİ KÜMESİ VOLÜM YAPISI

Volüm	Boyut (inline, xline, derinlik)	Kullanım
train_seismic	$401 \times 701 \times 255$	Eęitim + doğrulama
test1_seismic	$200 \times 701 \times 255$	Test1 (inline yön)
test2_seismic	$601 \times 200 \times 255$	Test2 (crossline yön)

Tablo II
F3 SINIF DAĞILIMI (EĞİTİM VOLÜMÜ, PİKSEL ORANLARI)

ID	İsim	%	Zorluk
0	Upper North Sea	28.09	Kolay
1	Lower North Sea	11.89	Orta
2	Rijnland	48.59	Baskın — naif tahmin
3	Scruff	6.64	Zor (ince banding)
4	Zechstein	3.28	Çok zor (anizotropik)
5	Under Zechstein	1.51	En zor (azınlık + daęınık)

2B omurgalarla uyumlu kalırken depth eksenindeki süreklilik bilgisini kısmen koruduęu için pratik bir uzlaşma sağlar [10].

C. Loss Fonksiyonları

Sınıf dengesizlięi probleminde Focal loss [5] azınlık sınıflarına odaklanmayı kolaylaştırır; Dice ve Lovász-Softmax [6] ise IoU ölçütüne doğrudan yöneliktir. Lovász-Softmax özellikle IoU yüzey-doęrultusunda türevli yaklaşıık optimizasyon sağlar ve çok sınıflı segmentasyon problemlerinde yaygın olarak kullanılır.

III. VERİ KÜMESİ: NETHERLANDS F3 BLOCK


F3 Hollanda kıyaaltı bloęu, Kuzey Denizi'nde yer alan 24×16 km ölçekli 3B sismik bir hacimdir. Veri Alaudah 2019 [1] tarafından 6 jeolojik fasiyes için etiketlenmiş ve halka açık olarak yayımlanmıştır (CC-BY-SA 3.0, Zenodo). Volümler $[-1, 1]$ aralıęına önceden normalize edilmiştir. Boyutlar Tablo I'de verilmiştir.

A. 6 Fasiyes Sınıfı ve Sınıf Dengesizlięi

Eęitim volümünde sınıfların piksel oranları büyük dengesizlik göstermektedir (Tablo II). Rijnland sınıfı (S2) örneklerin yaklaşık yarısını oluştururken, Under Zechstein (S5) yalnızca %1.5 paya sahiptir. Bu dengesizlik, naif bir modelin çoęunluk sınıfına yatkın tahminler üretmesine ve azınlık sınıflarda IoU deęerlerinin çökmesine neden olur.

IV. METODOLOJİ

Önerilen sistemin genel akışı şu şekildedir: 2.5D ön işleme $\rightarrow$ DeepLabV3+ + EfficientNet-B4 omurgalı segmentasyon $\rightarrow$ QuadrupleLoss ile eğitim $\rightarrow$ crossline-uyarlı augmentasyon $\rightarrow$ çok-ölçekli TTA $\rightarrow$ çoklu-tohum softmax ortalaması.



Şekil 1. 2.5D girdi temsili: ilgilenilen i . kesit ve ± 2 komşusu kanal ekseninde yığılarak $[s_{i-2}, s_{i-1}, s_i, s_{i+1}, s_{i+2}] \in \mathbb{R}^{5 \times H \times W}$ tensörü oluşturulur. Sismik volümün derinlik eksenindeki yerel sürekliliği bu temsille kısmen korunmuş olur.

A. Mimari: DeepLabV3+ + EfficientNet-B4

DeepLabV3+ [2], Atrous Spatial Pyramid Pooling (ASPP) modülünü çok-ölçekli bağlam yakalamak için decoder modülüyle birleştiren bir encoder-decoder ağıdır. ASPP, farklı genişlik (dilation) oranlarındaki paralel atrous konvolüsyonlarla yerel ve global özellikleri birlikte temsil eder; sismik tabakaların farklı kalınlık ölçeklerine uyum açısından elverişlidir.

Omurga olarak EfficientNet-B4 [3] (ImageNet ön-egitimli) seçilmiştir; bileşik ölçekleme stratejisi ile parametre/doğruluk dengesi yüksek olan bu model, ResNet-50'ye göre $\sim 24M$ parametre ile yüksek temsil kapasitesi sağlar. `segmentation_models_pytorch` [4] kütüphanesi ile gerçekleştirilmiştir.

B. 2.5D Girdi Temsili (5 kanal)

Her giriş örneği, ilgilenilen kesitin ± 2 komşusu ile birlikte 5 ardışık kesidin kanal eksenine yığılmasıyla oluşturulur (Şekil 1). Bu temsil hem ImageNet ön-egitimli omurganın çok-kanallı giriş beklentisiyle uyumludur (ilk konvolüsyon 5 kanala uyarlanır) hem de derinlik eksenini boyunca yerel bağlamı korur. Önceki sürümler (v5–v7) 3 kanal kullanmıştır; 5 kanal geçişiyle özellikle anizotropik Zechstein morfolojisinin temsilde kazanım elde edilmiştir (Bölüm V).

C. QuadrupleLoss

Eğitim hedefi $\mathcal{L}$, dört kayıp bileşeninin ağırlıklı toplamıdır:

$$\mathcal{L} = 0.30 \mathcal{L}_{\text{LS-CE}} + 0.25 \mathcal{L}_{\text{Dice}} + 0.25 \mathcal{L}_{\text{Focal}} + 0.20 \mathcal{L}_{\text{Lovász}}, \quad (1)$$

burada $\mathcal{L}_{\text{LS-CE}}$ etiket-yumuşatmalı (smoothing $\varepsilon=0.1$) çapraz-entropi, $\mathcal{L}_{\text{Dice}}$ çok-sınıflı Dice kaybı, $\mathcal{L}_{\text{Focal}}$ Focal kayıp ($\gamma=2$, sınıf frekanslarının tersiyle ağırlıklandırılmış), $\mathcal{L}_{\text{Lovász}}$ ise Lovász-Softmax kaybıdır. Ağırlık katsayıları (0.30/0.25/0.25/0.20); LS-CE kararlılığını koruyacak biçimde baskın kalırken, IoU-yönelimli bileşenler (Dice + Lovász) toplam %45 ağırlık almakta, sınıf-dengesizliği düzeltici Focal %25 pay almaktadır. Bu konfigürasyon sınırlı sayıda ön-deneme (sırasıyla 0.5/0.2/0.2/0.1, 0.4/0.3/0.2/0.1

ve eşit ağırlıklı varyantlar) üzerinden doğrulama mIoU'sunu maksimize etme amacıyla seçilmiştir; tam bir grid-search yapılmamış, bu kararın hassasiyet analizi gelecek çalışmalar arasında bırakılmıştır. Lovász bileşeni, AMP (otomatik karışık duyarlık) altında FP16'da NaN üretebildiği için yalnızca bu bileşen **FP32 sarmalayıcı** içinde hesaplanmaktadır.

D. Veri Artırma ve Crossline-Uyarlılığı

Albumentations [8] ile gerçekleştirilen artırımlar arasında HorizontalFlip, ShiftScaleRotate, ElasticTransform, GridDistortion, RandomBrightnessContrast, GaussNoise, CoarseDropout ve genlik kutuplaşması ters çevirme (polarity inversion, $\times -1$ çarpma) bulunmaktadır. Jeofizik kuralı gereği, derinlik eksenini ters çevrilemediğinden **VerticalFlip kullanılmaz**.

Crossline-uyarlı augmentasyon: Crossline kesitlerinde Zechstein morfolojisi daha kıvrımlı ve diapir benzeri olduğundan, bu görüntülere inline'lara göre daha agresif ElasticTransform ve GridDistortion uygulanmıştır. Bu, Class 4 Test2 (crossline) IoU'sunda kayda değer kazanç sağlamıştır (Tablo VI).

Sınıf-bazlı örnekleme: **WeightedRandomSampler** ile S4 (Zechstein) ve S5 (Under Zechstein) sınıfları $\times 10$ ile boost edilmiştir.

E. Yol A Metodoloji Düzeltmesi

Önceki sürümlerin (v7-bozuk) inline bölünmesinde üç ayrı sızıntı tespit edilmiştir:

- **Sızıntı 1 (Bitişik blok doğrulama).** `val_inline_idx = np.arange(320, 401)` ile son %20 inline bitişik bir blok olarak doğrulamaya ayrılmıştı; bu durum konum yanlılığına yol açmaktaydı.
- **Sızıntı 2 (Crossline 3B sızıntı).** `train_xline_idx = np.arange(0, 601)` ile tüm crossline kesitleri eğitim setine alınıyordu; ancak her crossline kesidi inline doğrulama indekslerinden geçtiği için doğrulama pikselleri eğitimde *görülüş* oluyordu.
- **Sızıntı 3 (2.5D komşuluk sızıntısı).** Doğrulama sınırındaki inline 320 kesidi, eğitim sırasında 319 ve 321 kesitleriyle aynı 2.5D yığında yer alıyordu.

Yol A düzeltmesi: Doğrulama indeks aralığı ortaya kaydırıldı (`val_inline_idx = np.arange(160, 240)`); eğitim iki blok halinde $[0, 158] \cup [242, 401)$ olarak ayrıldı. Doğrulama bloğunun her iki yanına BUFFER=2 kesitlik tampon konularak 2.5D komşuluk sızıntısı engellendi. Crossline kesitlerinde `train_inline_mask` boolean dizisi ile doğrulama bölgesine ait pikseller görüntüden *kirpıldı*. Test2 ayrı bir volüm olduğundan maskelenmedi. Düzeltme öncesi/sonrası karşılaştırma Bölüm V'da sunulmuştur.

F. Eğitim Ayarları

AdamW iyileştirici ($\text{lr}=1 \times 10^{-4}$, $\text{weight_decay}=1 \times 10^{-3}$) ve CosineAnnealingWarmRestarts ($T_0=25$, $\eta_{\min}=1 \times 10^{-6}$) zamanlayıcısı kullanılmıştır. Mixup [7] $\alpha=0.2$ ile batch

başına $p=0.5$ olasılıkla uygulanmıştır. Toplam 100 devir, 25 devir sabırlı erken durdurma. AMP ile karışık duyarlık (Lovász hariç), batch 4×6 adım birikimi = efektif batch 24. Çözünürlük 384×384 . Eğitim süresi tek seed için ~ 5 saat (NVIDIA RTX 3060 Ti, 8 GB).

G. Çok-Ölçekli Test-Zamanı Artırma (TTA)

Çıkarım sırasında her test örneği için şu artırımlar uygulanır ve softmaks çıktıların ortalaması alınır:

- Orijinal
- HorizontalFlip
- Polarity inversion ($\times -1$)
- Çok-ölçekli yeniden örnekleme: 0.75, 1.0, 1.25

H. Çoklu-Tohum Topluluk

v9 mimarisi üç farklı rastgele tohum (seed $\in \{42, 43, 44\}$) ile *birebir aynı* hiperparametrelerle bağımsız olarak eğitilmiş, çıkarım sırasında çok-ölçekli TTA çıktıların softmaks ortalaması alınarak topluluk oluşturulmuştur:

$$\hat{p}(c | \mathbf{x}) = \frac{1}{3} \sum_{s \in \{42, 43, 44\}} p_s(c | \mathbf{x}), \quad (2)$$

$$\hat{y} = \arg \max_c \hat{p}(c | \mathbf{x}).$$

V. DENEYSEL SONUÇLAR

A. Değerlendirme Protokolü

Tüm metrikler 384×384 yeniden örneklenmiş alanda hesaplanmıştır. Birleşik (Combined) metrikleri, Test1 ve Test2 hacimlerinin tüm test piksellerinin birleştirilmesiyle elde edilen toplam karmaşıklık matrisinden hesaplanmıştır. Aşağıdaki metrikler raporlanmaktadır:

- **mIoU** — Sınıf ortalaması IoU,
- **Dice** — Sınıf ortalaması Dice,
- **PA** — Piksel doğruluğu,
- **MCA** — Sınıf ortalaması doğruluğu,
- **FwIoU** — Frekans-ağırlıklı IoU (Alaudah ile birebir kıyas için).

B. Sürüm Evrimi (v3 $\rightarrow$ v9-Topluluk)

Tablo III mimari ve metodoloji değişikliklerinin Birleşik mIoU üzerindeki etkisini özetlemektedir.

v7-bozuk sürümünün görünürdeki 0.7926 değeri, üç veri sızıntısının yarattığı yapay bir yükselmedir; metodoloji düzeltmesi (Yol A) sonrası bu değer 0.7668'e düşmüştür. Bu *kötüleşme değil*, gerçek genelleme performansının ortaya çıkmasıdır.

C. Yol A Düzeltmesinin Etkisi

Tablo IV, Yol A düzeltmesinin Test1 / Test2 / Birleşik metriklere etkisini göstermektedir. Test1 ve Test2 mIoU'ları sırasıyla 2.6 ve 3.0 puan düşmüş; daha da önemlisi, eğitim sırasındaki en iyi doğrulama mIoU değeri (0.6617, v7-bozuk) ile test sonuçları arasındaki +12.6 puanlık *paradoks* büyük ölçüde kapanmıştır.

Tablo III
SÜRÜM EVRİMİ — BİRLEŞİK mIoU
(v7-BOZUK SAYISI VERİ SIZINTISI İÇERİR; DÜZELTME SONRASI GERÇEK GENELLEME PERFORMANSI v7-FIXED'DİR.)

Sürüm	Birleşik mIoU
v3 (taban U-Net, ImageNet yok)	0.4012
v5 (EfficientNet-B4 + DeepLabV3+ + 320)	0.7582
v6 (+ 2.5D 3-kanal + WeightedSampler)	0.7692
v7-bozuk (veri sızıntılı)	0.7926
v7-fixed (+ Yol A düzeltme)	0.7668
v7-c4fix (+ 5-kanal + Lovász + xline-uyarlı aug)	0.7779
v9 (tek seed, + 384 + çok-ölçekli TTA)	0.7769
v9 Topluluk (3-seed)	0.7910 $\pm$ 0.006

Tablo IV
YOL A DÜZELTMESİ — ÖNCESİ VS. SONRASI

Metrik	v7-bozuk	v7-fixed
Test1 mIoU	0.7881	0.7625
Test2 mIoU	0.6986	0.6681
Birleşik mIoU	0.7926	0.7668
Birleşik Dice	0.8775	0.8603
Birleşik PA	0.9413	0.9319
Birleşik MCA	0.8975	0.8615
Birleşik FwIoU	—	0.8784

Tablo V
v9 TOPLULUK SINIF-BAZLI IoU — TEST1 / TEST2 / BİRLEŞİK

ID	Sınıf	Test1	Test2	Birleşik
S0	Upper North Sea	0.953	0.949	0.951
S1	Lower North Sea	0.809	0.815	0.812
S2	Rijnland	0.941	0.941	0.941
S3	Scruff	0.674	0.562	0.629
S4	Zechstein	0.843	0.183	0.803
S5	Under Zechstein	0.606	0.612	0.609

D. Sınıf-bazlı Performans ve Class 4 Evrimi

Tablo V, v9 **topluluk** modelinin Birleşik, Test1 ve Test2 sınıf-bazlı IoU değerlerini sunmaktadır. Beklendiği gibi azınlık ve morfolojik karmaşık sınıflar (S3 Scruff, S5 Under Zechstein) en zorlu olanlardır. Class 4 (Zechstein) Test1 IoU 0.843 değerine ulaşırken Test2'de 0.183'e çökmektedir; bu sınıfa özgü çoklu-test-kümesi davranışı Bölüm VI'da ayrıntılı tartışılmaktadır.

Class 4 Test2 IoU değeri ardışık metodoloji değişiklikleriyle önemli ölçüde iyileşmiştir (Tablo VI). v7-fixed'in 0.1177 değerinden v9'da 0.2304'e — görece olarak +%96 kazanç — ulaşılmıştır.

SFM (Seismic Foundation Model, Bölüm V-I) deneylerinde yarı-dondurulmuş enkoderli sürüm (SFM v1, etkin enkoder $l_r \approx 1.5 \times 10^{-6}$) Class 4 Test2 IoU 0.270 değerine ulaşmıştır; bu değer hem v9 topluluk ortalamasından (0.183) hem de tek-tohumlu SEED 42 *aykırı* sonucundan (0.230) yüksektir ve tüm denenen modeller arasında Zechs-

Tablo VI
CLASS 4 (ZECHSTEIN) TEST2 IOU EVRİMİ (KAYNAK MODELLER VE SFM İLE KARŞILAŞTIRMA)

Sürüm	Class 4 Test2 IoU
v7-fixed	0.1177
v7-c4fix (5-ch + Lovász + xline-uyarlı aug)	0.1820
v9 tek-seed (+ 384 + çok-ölçekli TTA)	0.2304
v9 Topluluk (gerçek değer)	0.183 ± 0.04
SFM v2 (ViT-B/16 full fine-tune)	0.201
SFM v1 (ViT-B/16 dondurulmuş enkoder)	0.270

Tablo VII
TEK-TOHUM SONUÇLARI (ÇOK-ÖLÇEKLİ TTA)

SEED	En iyi val	Birleşik	Test1	Test2	C4 T2
42 (v9)	0.8022	0.7769	0.7752	0.6869	0.2304
43	0.8271	0.7850	0.8041	0.6626	0.1560
44	0.8078	0.7920	0.8095	0.6727	0.1625
Ort.	—	0.7846	—	—	—
Std.	—	±0.0062	—	—	—

Tablo VIII
TOPLULUK VS. TEK-TOHUM (Δ : TOPLULUK – SEED 42)

Metrik	Topluluk	v9 (SEED 42)	Δ
Birleşik mIoU	0.7910	0.7769	+1.41
Birleşik PA	0.9402	0.9345	+0.57
Birleşik MCA	0.8734	0.8627	+1.07
Birleşik Dice	0.8769	0.8675	+0.94
Test1 mIoU	0.8043	0.7752	+2.91
Test2 mIoU	0.6771	0.6869	−0.98
Class 4 Test2	0.1834	0.2304	−4.70

tein crossline morfolojisinde en iyi performansı sergilemektedir. Bu bulgu, sismik-spesifik ön-eğitimin domain-shift altındaki zorlu sınıflar için ImageNet ön-eğitimine kıyasla potansiyel sağladığına işaret etmektedir (ayrıntılı tartışma Bölüm V-I).

E. Çoklu-Tohum Topluluk Sonuçları

3 bağımsız tohum ile elde edilen tek-tohum sonuçları (Tablo VII) ve topluluğun nihai sonuçları (Tablo VIII) aşağıdadır.

Topluluk Birleşik mIoU’da +1.41 puan, PA’da +0.57 puan ve MCA’da +1.07 puan kazanç sağlamıştır. Özellikle **Test1 mIoU değeri 0.804’e ulaşarak ≥ 0.80 eşiğini aşmıştır**; bu, sismik fasiyes literatüründe Alaudah coğrafi bölünmesine sadık kalan az sayıda yöntem arasında dikkat çekici bir sonuçtur. Test2 ve Class 4 Test2’de *ters yönlü* bir hareket bulunmaktadır; bu, sonraki alt bölümde tartışılan kritik akademik bulguya işaret eder.

F. Kritik Bulgu: Class 4 Tek-tohum Aykırı Değeri

SEED 42 (v9) modelinin Class 4 Test2 IoU sonucu (0.2304), diğer iki bağımsız tohumun (0.1560 ve 0.1625)

üzerinde belirgin biçimde sapma göstermektedir. 3 tohum üzerinden ortalama 0.183 ± 0.04 olarak hesaplanır. Bu durum, tek-tohumla yapılan rapor edilen 0.230 sonucunun istatistiksel olarak *aykırı/şanslı* bir sonuç olduğunu açıkça ortaya koymaktadır.

Bu bulgu, sismik segmentasyon literatüründe yaygın olarak rastlanan *tek-tohum raporlama* pratiğinin (özellikle azınlık sınıflarda) önemli risklerinden birinin çıplak bir örneğini sunmaktadır: dar bir aralıkta salınan IoU değerleri, tek bir koşulda raporlanabilmektedir. Tezin asıl sayısı olarak *topluluk değerinin* (0.183 ± 0.04) kullanılması, akademik dürüstlük açısından önerilmektedir.

G. Literatür Karşılaştırması

Tablo IX, Alaudah 2019 ve bizim çalışmamızın metriklerini birebir karşılaştırılabilir formda sunmaktadır. Diğer literatür sayıları (Wiley 2022, CONSS 2023, AdaSemSeg 2025) farklı bölünmeler kullandıkları için doğrudan kıyaslanamamakta; bu yüzden tabloda referans amaçlı eklenmiştir.

Tablo IX, çoklu-tohum topluluğumuzun **piksel doğruluğunda** (PA 0.940 vs Alaudah 0.905, +3.5 puan), **sınıf ortalaması doğruluğunda** (MCA 0.873 vs 0.817, +5.6 puan) ve **frekans-ağırlıklı IoU’da** (FwIoU 0.891 vs 0.832, +5.9 puan) Alaudah 2019 en iyi temel modelinin üzerinde sonuç verdiğini ortaya koymaktadır. FwIoU değeri, test kümesi etiket dosyalarından doğrudan hesaplanan gerçek-değer (GT) sınıf frekansları (Birleşik: S0: %21.5, S1: %9.9, S2: %50.7, S3: %6.0, S4: %9.6, S5: %2.3) ile topluluk modelinin sınıf-bazlı IoU değerlerinin ağırlıklı toplamı olarak hesaplanmıştır (`scripts/compute_fwIoU_ensemble.py`; Tablo X Test1/Test2/Birleşik kırılımı). Üstelik bu karşılaştırma Alaudah’ın *orijinal coğrafi bölünmesine sadık kalan* ve veri sızıntılarından arındırılmış (*Yol A* düzeltmesi) bir protokol üzerinde yapılmıştır.

Bu karşılaştırmanın metodolojik nüansı, bizim metriklerimizin 384×384 yeniden örneklenmiş alanda hesaplanmış olmasıdır; Alaudah orijinal çözünürlükte ($701 \times 255 / 401 \times 255$) değerlendirici çalıştırmıştır. Mutlak tutarlılık için orijinal-çözünürlük değerlendiricinin yeniden çalıştırılması *bekleyen iş* olarak işaret edilmiştir. Ancak Alaudah baseline’ı ile aramızdaki +3.5/+5.6/+6.0 puanlık farkın yalnızca evaluator çözünürlüğü etkisiyle açıklanması güçtür; yeniden örneklemenin tipik etkisi $\lesssim 1$ puandır.

H. Bileşen Ablation’ı

v9 mimarisinin üç tasarım kararının (Lovász-Softmax kaybı, 5-kanallı 2.5D giriş, crossline-uyarlı augmentasyon) Birleşik ve Class 4 (Zechstein) Test2 metriklerine etkisini ölçmek amacıyla bir bileşen ablation’ı yürütülmüştür. Her ablation, v9 baseline (SEED =42) ile *birebir aynı* hiperparametrelerle eğitilmiş, yalnızca ilgili bileşen devre dışı bırakılmıştır. Ablation maliyeti nedeniyle tek tohumla (SEED =42) yürütülmüş, çoklu-tohum ablation gelecek iş olarak işaretlenmiştir. Sonuçlar Tablo XI’de özetlenmiştir.

Tablo IX
F3 ÜZERİNDE RAPOR EDİLEN SAYILARIN KARŞILAŞTIRMASI

Yöntem	Yıl	Bölünme	mIoU	PA	MCA	Dice	FwIoU
Alaudah section + aug + skip (en iyi baseline) [1]	2019	Alaudah coğra-fi	—	0.905	0.817	—	0.832
Bizim v7-fixed (referans baseline)	2026	Alaudah coğra-fi	0.767	0.932	0.862	0.860	0.878
Bizim v9 (tek-seed)	2026	Alaudah coğra-fi	0.777	0.935	0.863	0.867	0.882
Bizim v9 Topluluk (3-seed) ⇒ aktif final	2026	Alaudah coğra-fi	0.791 ± 0.006	0.940	0.873	0.877	0.891
Bizim SFM v2 (ViT-B/16 fine-tune)	2026	Alaudah coğra-fi	0.768	0.936	0.856	0.857	0.888
Abid ve ark. (Wiley) ensemble [11]	2022	rastgele yama (7 sınıf)	0.939 [†]	0.985 [†]	—	—	—
CONSS yarı-denetimli [12]	2023	kendi düzeni	0.946 [†]	—	—	—	—
AdaSemSeg Baseline-1 [13]	2025	farklı F3 split	—	0.91 [†]	0.89 [†]	—	0.86 [†]
UmixClick (interaktif) [15]	2025	belirsiz, kullanıcı tıklamalı	0.767 [†]	0.935 [†]	—	—	—
SFM (Sheng ve ark.) [14]	2024	F3 için raporlanmadı (Pari-haka 0.798)	—	—	—	—	—

[†] Farklı bölünme/sınıf sayısı — birebir karşılaştırılabilir değildir.

Tablo X
TOPLULUK MODELİNİN FWIoU DEĞERLERİ (TEST KÜMESİ KIRILIMI)

Test kümesi	FwIoU
Test1 (inline)	0.8888
Test2 (crossline)	0.8964
Birleşik	0.8908
Alaudah 2019 (Birleşik) [1]	0.832

Tablo XI
BİLEŞEN ABLATION'I — V9 BASELINE (SEED =42) VS. TEK-BİLEŞEN KAPALI VARYANTLAR

Konfigürasyon	Birleşik	Δ Birleşik	Δ C4 T2
v9 baseline (tam pipeline)	0.7769	—	— (C4 T2 = 0.7304)
— Lovász (TripleLoss)	0.7792	+0.23	−1.43
— 5-kanal → 3-kanal (±1)	0.7714	−0.55	−11.05
— xline-uyarlı aug	0.7688	−0.81	−9.88

Ablation üç bulguyu doğrulamaktadır: (i) **5-kanallı 2.5D giriş ve crossline-uyarlı augmentasyon Class 4 Test2 performansı için olmazsa olmaz** bileşenlerdir; her birinin kaldırılması Class 4 Test2 IoU'sunu yaklaşık 10 puan düşürmektedir. Bu, Class 4 odaklı tasarım kararlarının *post-hoc gerekçelendirmesi* değil *niceliksel doğrulanmasıdır*. (ii) **Lovász-Softmax kaybı** Birleşik mIoU üzerinde küçük negatif etki gösterse de (*TripleLoss* +0.23 puan), doğrudan IoU surrogate olarak Class 4 azınlık sınıfında 1.43 puan tutarlı katkı sağlamaktadır. (iii) Birleşik mIoU değişimleri (±0.81 puan) sınıf-bazlı etkilerin

(±11 puan) çok altındadır; bu, agregre metriklerin azınlık-sınıf gerilemelerini gizleyebildiğine işaret eder ve sınıf-bazlı raporlamanın gerekliliğini ampirik olarak vurgulamaktadır.

I. Sismik Temel Modeli (SFM) ile Karşılaştırma

ImageNet ön-eğitilmiş EfficientNet-B4 omurgasının sismik veri özelinde en iyi seçim olup olmadığını sınamak ve son dönem literatürde yaygınlaşan *foundation model fine-tuning* paradigmasını F3 üzerinde test etmek amacıyla, Sheng ve arkadaşlarının [14] Sismik Temel Modeli (SFM, ViT-B/16) ön-eğitilmiş ağırlıkları aynı eğitim/doğrulama bölünmesi (*Yol A*), aynı 5-kanal 2.5D girdi (sismik kanallar 5 → 1 *channel_adapter* ile ViT'in tek-kanal beklentisine uyarlanmıştır) ve aynı QuadrupleLoss konfigürasyonu ile fine-tune edilmiştir. İki varyant denenmiştir: (i) **SFM v1**, enkoder katman-katman küçülen öğrenme oranlarıyla ($lr_{enc} = 5 \times 10^{-5}$, **layer_decay**=0.75, en derin blokta efektif $lr \approx 1.5 \times 10^{-6}$) hafifçe ince-ayar edilmiş, segmentasyon başlığı ise daha agresif öğrenme oranıyla ($lr_{head} = 10^{-3}$) eğitilmiştir (60 devir, 36. devirde erken durdurma); bu konfigürasyon pratikte *yarı-dondurulmuş* bir enkoder davranışı sergilemektedir; (ii) **SFM v2**, enkoderin daha agresif şekilde fine-tune edildiği uzun koşu ($lr_{enc} = 2 \times 10^{-4}$, **layer_decay**=0.9, en derin blokta efektif $lr \approx 2.8 \times 10^{-5}$; 80 devir, azınlık-sınıf boost faktörü 15). Sonuçlar Tablo XII'de özetlenmiştir.

Birleşik mIoU açısından SFM varyantları v9 topluluğunu geçememiştir (SFM v2: 0.768, v9 topluluk: 0.791); bu fark Class 2 Rijnlend ve Class 5 Under Zechstein sınıflarında SFM'in nispeten düşük IoU'larından kaynaklanmaktadır. *Bununla birlikte*, sonuçlar tek-lider bir model

Tablo XII
v9 TOPLULUK VS. SFM VIT-B/16 FINE-TUNE VARYANTLARI
(BİRLEŞİK METRİKLER)

Model	mIoU	PA	MCA	FwIoU
v9 Topluluk (ana)	0.791	0.940	0.873	0.891
SFM v2 (tam fine-tune)	0.768	0.936	0.856	0.888
SFM v1 (yarı-dondurulmuş enc.)	0.728	0.922	0.823	0.862

olmadığını, her varyantın belirli kesitlerde avantaj sergilediğini göstermektedir: SFM v1 **Class 4 Test2 (Zechstein crossline) IoU değerinde 0.270 ile tüm denenen modellerin en iyisidir** (v9 topluluk: 0.183, v9 tek-tohumlu aykırı: 0.230, SFM v2: 0.201); SFM v2 ise *en iyi doğrulama mIoU* (0.823 vs. v9 SEED 42 0.802) ve *Class 4 Birleşik IoU* (0.805 vs. v9 SEED 42 0.784) metriklerinde lider olmuştur. Buna karşılık SFM v1, Class 4'teki kazanımının karşılığında *Class 5 Test2 IoU*'da v9'a göre -14 puan kayıp vermektedir; yani Class 4 odaklı boost'un başka azınlık sınıflarda gerileme pahasına geldiği görülmektedir.

İki olası açıklama vardır: (a) SFM enkoderi ~100k saatlik sismik veri üzerinde maskelenmiş otoenkoder hedefiyle ön-egitilmiştir; bu süreç, ImageNet'in doğal görüntü bias'ına maruz kalmış EfficientNet-B4'e göre sismik tekstüre özgü öncül bilgileri kodlamış olabilir. (b) Yarı-dondurulmuş enkoder yaklaşımı (SFM v1), sınırlı fine-tuning verisiyle aşırı uyum (overfitting) riskini azaltarak Zechstein gibi morfolojik olarak farklı bir bölgede daha kararlı özellikler üretebilir. SFM v2'nin daha agresif enkoder fine-tune'unda Class 4 Test2 IoU'nun 0.201'e gerilemesi bu hipotezi destekleyici niteliktedir: enkoder tam öğrenince inline-baskın eğitim verisinin morfolojik bias'ına yatkımlaşmakta ve crossline yöndeki genelleme bozulmaktadır.


Önemli çekince. SFM v1 ve v2 sonuçları tek tohum (SEED =42) ile elde edilmiştir; SFM ailesi için multi-seed ablation yapılmamıştır. Bölüm V-F'de v9 modeli için somutlanan tek-tohum aykırı değer riski (Class 4 Test2 IoU 0.230'un üç-tohum gerçek değeri 0.183 ± 0.04 olarak görüldü) prensip olarak SFM ölçümleri için de geçerlidir. Bu nedenle SFM v1'in Class 4 Test2'deki 0.270 üstünlüğü, *yüksek varyans bandında değerlendirilmesi gereken* potansiyel bir bulgu olarak raporlanmaktadır; istatistiksel olarak doğrulanmış bir üstünlük iddiası için en az üç-tohumlu SFM tekrarı gerekmektedir ve bu, çoklu-tohum ablation paketiyle birlikte gelecek iş olarak işaretlenmiştir.

Topluluk ve SFM varyantlarının birleştirildiği hibrit bir çıkarım yaklaşımı (örn. v9 topluluk ortalaması + SFM v1 yalnızca Class 4 alanlarında oy çoğunluğu) gelecek çalışmalar arasında yer almaktadır.

VI. TARTIŞMA VE SINIRLILIKLAR

A. Class 4 Test2 Aykırı Değeri — Akademik Etik

Bölüm V-F'de raporlanan tek-tohum aykırı değeri, sismik segmentasyon çalışmalarında *varyans raporlanmaması*



Şekil 2. Class 4 (Zechstein) morfoloji karşılaştırması. Üst: Test1 (inline) yatay-katmanlı tabaka. Alt: Test2 (crossline) diapir tipi anizotropik kıvrımlı yapı. Aynı jeolojik birimin iki test kümesindeki bu yapısal farkı, modelin Test1'de 0.843 IoU başarımı ile Test2'de 0.183'e düşüşünü açıklamaktadır.

yaygın sorununa somut bir örnek teşkil etmektedir. Önerilen pratik: a) en az üç tohumla ortalama $\pm$ standart sapma raporlanması, b) topluluk modeli sonuçlarının tek-tohum sonuçlarına *tercih edilmesi*, c) azınlık sınıflarda metriklerin geniş güven aralıkları olduğunun açıkça kabul edilmesi.

B. Bileşen Katkılarının Yorumu

Bölüm V-H'de raporlanan ablation sonuçları, v9 tasarımının üç bileşen kararının da *Class 4 odaklı* olduğunu niceliksel olarak ortaya koymaktadır: 5-kanallı 2.5D giriş (Class 4 Test2 üzerinde -11.05 puan) ve crossline-uyarlı augmentasyon (-9.88 puan) Class 4 Zechstein crossline morfolojisi için *kritik* bileşenler iken, Lovász-Softmax katkısı küçük ama tutarlı kalmaktadır (-1.43 puan). Birleşik mIoU'daki değişimlerin sınıf-bazlı etkilerin çok altında kalması (± 0.81 vs. ± 11 puan), agregre metriklerin azınlık-sınıf gerilemelerini gizleyebildiğini ampirik olarak göstermektedir; bu, sismik fasiyes literatüründe yalnızca birleşik metrik raporlamanın yetersizliğine işaret eden bağımsız bir bulgudur.

C. Test2 ve Crossline Yön Bağımlılığı

Topluluk Test2 mIoU'da hafif gerileme göstermiştir (-0.98 puan). Topluluk genel olarak varyansı söndürürken, Test2 dağılımı eğitim dağılımından önemli ölçüde sapmaktadır (Zechstein crossline yönde anizotropik). Şekil 2, Class 4'ün Test1 (inline) ve Test2 (crossline) yönlerindeki morfolojik farkını göstermektedir: Test1'de Zechstein tabakası yatay-katmanlı düzenli bir banding sergilerken, Test2'de aynı sınıf diapir tipi kıvrımlı/dikey morfoloji kazanmaktadır. 2.5D 5-kanal temsili bu yapısal farklılığı yakalamakta yetersiz kalmakta; SFM v1 dondurulmuş enkoderin Test2 Class 4'te elde ettiği 0.270 IoU (Bölüm V-I, Tablo XII) sismik-spesifik ön-egitimin bu yön bağımlılığını kısmen kapatabileceğine işaret etmektedir.

Bu çöküşün niteliğini daha açık ortaya koymak amacıyla, v9 SEED 42 modelinin Test2 Class 4 gerçek-değer (ground truth) pikseline yönelik tahmin dağılımı karmaşıklık matrisinden çıkarılmıştır (Tablo XIII). Toplam

Tablo XIII
v9 SEED 42 — CLASS 4 (ZECHSTEIN) TEST2 GT PİKSELLERİNİN
TAHMİN DAĞILIMI

Tahmin	Sınıf	Pay (%)
S4	Zechstein (doğru)	34.5
S5	Under Zechstein	43.9
S3	Scruff	21.1
S2	Rijnland	0.5
S0-S1	Üst kuzey deniz birimleri	0.1

~231k Class 4 GT pikselinin yalnızca **%34.5'i doğru** olarak Zechstein sınıfına atanmış; **%43.9'u komşu Under Zechstein (S5)** ve **%21.1'i Scruff (S3)** sınıflarına yanlış atfedilmiştir. Bir başka deyişle, model Test2'de Zechstein'i *predominantly Under Zechstein* olarak yorumlamaktadır; bu, iki sınıfın crossline yönündeki spektral ve morfolojik imzasının ayırsız hâle geldiğine işaret etmektedir.

Bu durum, gerçek anlamda alan-uyarlama (*domain adaptation*) veya sismik-spesifik temel modeli (*foundation model*) ince-ayarı gerektirebilir; gelecek çalışmalar olarak işaret edilmiştir. SFM v1'in aynı sınıfta 0.270 IoU değeri elde etmesi (Bölüm V-I), bu yöndeki çözüm potansiyeline işaret eden somut bir bulgudur.

D. Değerlendirme Çözünürlüğü Kaveati

Sayılarımız 384×384 yeniden örneklenmiş alanda hesaplanmıştır; Alaudah ise orijinal çözünürlüğünde ($701 \times 255/401 \times 255$) değerlendirici çalıştırmıştır. Sayısal olarak Alaudah temel modelinin PA, MCA ve FwIoU metriklerinde sırasıyla +3.5, +5.6 ve +6.0 puan üzerinde sonuç elde etmiş olsak da, orijinal-çözünürlük değerlendiricinin yeniden çalıştırılması (*bekleyen iş*) ile kıyasın mutlak tutarlılığa kavuşması gerekmektedir. Bununla birlikte, yeniden örneklemenin metrikler üzerindeki tipik etkisi $\lesssim 1$ puan olduğundan, gözlenen 3.5–6.0 puanlık farkın yalnızca evaluator etkisine atfedilmesi olanaklı görünmemektedir.

E. Diğer Bilinen Sınırlılıklar

- **Tek-veri kümesi.** Yalnızca F3 üzerinde test edildi; farklı sismik veri kümeleri (örn. Penobscot, Parihaka) ile transfer denenmedi.
- **Ablasyon tek-tohum.** Bölüm V-H'de raporlanan bileşen ablation'ı (Lovász, 5-kanal 2.5D, crossline-uyarlı augmentasyon) tek tohumla (SEED =42) yürütülmüştür; bulgular ana eğilim göstergesi niteliğindedir ve ablation kararlarına ilişkin güven aralığı hesaplanmamıştır. TTA varyant ablation'ı (multi-scale vs. HFlip-only vs. no-TTA) ile Mixup, Focal α ve etiket-yumuşatma parametrelerinin tek-tek ablation'ı bu çalışma kapsamı dışında bırakılmış, çoklu-tohum ablation paketiyle birlikte gelecek iş olarak işaretlenmiştir.
- **AMP+Lovász NaN sorunu.** 384×384 'te Lovász FP16'da NaN üretiyordu; FP32 sarmalayıcı ile

çözüldü — bu, raporlanması gereken bir uygulama nüansıdır.

VII. SONUÇ

Bu çalışmada, F3 Hollanda sismik fasiyes kıyaslama veri kümesi üzerinde metodoloji-sağlam bir DeepLabV3+ + EfficientNet-B4 sistemi sunulmuştur. Önerilen v9 mimarisi, 2.5D 5-kanal girdi, QuadrupleLoss, crossline-uyarlı augmentasyon ve çok-ölçekli TTA bileşenleriyle inşa edilmiş; üç ayrı veri sızıntısı (*Yol A*) düzeltilmiştir. 3 bağımsız tohum üzerinden softmaks ortalamasıyla elde edilen topluluk; Birleşik mIoU = 0.791 ± 0.006 , PA = 0.940, MCA = 0.873 ve **Test1 mIoU** = 0.804 değerlerine ulaşmıştır. Sonuçlarımız, **Alaudah 2019 en iyi temel modelinin PA (+3.5 puan), MCA (+5.6 puan) ve FwIoU (+5.9 puan) metriklerinde sayısal olarak üzerinde**; yalnızca evaluator çözünürlüğü kaveati bulunmaktadır. Tek-tohum raporlamanın güvenilirlişi olduğunu gösteren kritik bir akademik bulgu da sunulmuştur: tek-tohumda görülen Class 4 Test2 0.230 değeri, üç-tohum gerçek değeri olan 0.183 ± 0.04 ile karşılaştırıldığında istatistiksel bir aykırı değer çıkmıştır. Ek olarak, Sismik Temel Modeli (SFM)'in Alaudah protokolünde ilk fine-tune sonuçları raporlanmış; dondurulmuş enkoder sürümünün Class 4 Test2'de 0.270 IoU ile tüm denenen modellerin üzerinde performans sergilediği gösterilmiştir. Gelecek çalışmalar olarak (i) orijinal-çözünürlük değerlendirici ile Alaudah birebir kıyas, (ii) v9 topluluk ve SFM'in sınıf-bazlı hibrit çıkarımı (Class 4 alanında SFM oylama, diğerlerinde v9 topluluk), (iii) alan-uyarlama yöntemleriyle Test2/crossline performansının iyileştirilmesi önerilmektedir.

YENİDEN ÜRETİLEBİLİRLİK

Kaynak kod ve eğitim/değerlendirme komut dosyaları proje deposunda açık biçimde mevcuttur (`deeplabv3plus_v9.ipynb`, `ensemble/`, `ablation/` klasörleri). SFM fine-tune deneyleri ve sonuç JSON dosyaları `archive/sfm/` altında arşivlenmiştir; `archive/sfm/metrics/sfm_finetune_metrics.json` (SFM v1) ve `sfm_finetune_v2_metrics.json` (SFM v2) tam metrik ve karmaşıklık matrislerini içerir. SFM ön-eğitilmiş ağırlıkları `shenghanlin/SeismicFoundationModel` GitHub deposu üzerinden elde edilmiştir. FwIoU değerleri Alaudah formülü ($FwIoU = \sum_c f_c \cdot IoU_c$) ile hesaplanmıştır; sınıf frekansları f_c test kümesi etiket dosyalarındaki (`test1_labels.npy` $\cup$ `test2_labels.npy`) gerçek-değer piksel sayımlarından, sınıf-bazlı IoU değerleri topluluk modelinin Birleşik karmaşıklık matrisinden alınmıştır (`scripts/compute_fwio_u_ensemble.py`). Hesaplama betiği JSON çıktılarından doğrudan yeniden üretilebilir. Veri seti Zenodo 10.5281/zenodo.3755060 üzerinden indirilebilir. Tüm tohumlar (42, 43, 44), öğrenim oranı, scheduler ve mimari parametreleri Bölüm IV'de raporlanmıştır. Tüm metrikler 384×384 yeniden örneklenmiş alanda hesaplanmıştır.

TEŞEKKÜR

Yazar, Bilgisayarda Görme dersi kapsamında değerli geri bildirimleri için ders sorumlusuna; veri kümesini kamuya açtıkları için Alaudah ve arkadaşlarına teşekkür eder. Kullanılan tüm açık kaynaklı kütüphaneler (PyTorch, segmentation_models_pytorch, Albumentations) topluluklarına ayrıca teşekkür edilir.

KAYNAKLAR

- [1] Y. Alaudah, P. Michalowicz, M. Alfarraj, ve G. AlRegib, *A Machine Learning Benchmark for Facies Classification, Interpretation*, cilt 7, no. 3, ss. SE175–SE187, 2019.
- [2] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, ve H. Adam, *Encoder–Decoder with Atrous Separable Convolution for Semantic Image Segmentation*, *Proc. ECCV*, 2018, ss. 801–818.
- [3] M. Tan ve Q. V. Le, *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*, *Proc. ICML*, 2019.
- [4] P. Iakubovskii, *Segmentation Models PyTorch*, GitHub: [qubvel/segmentation_models_pytorch](https://github.com/qubvel/segmentation_models_pytorch), 2019.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, ve P. Dollár, *Focal Loss for Dense Object Detection*, *Proc. ICCV*, 2017, ss. 2980–2988.
- [6] M. Berman, A. R. Triki, ve M. B. Blaschko, *The Lovász-Softmax Loss: A Tractable Surrogate for the Optimization of the Intersection-over-Union Measure in Neural Networks*, *Proc. CVPR*, 2018, ss. 4413–4421.
- [7] H. Zhang, M. Cisse, Y. N. Dauphin, ve D. Lopez-Paz, *mixup: Beyond Empirical Risk Minimization*, *Proc. ICLR*, 2018.
- [8] A. Buslaev ve ark., *Albumentations: Fast and Flexible Image Augmentations*, *Information*, cilt 11, no. 2, s. 125, 2020.
- [9] B. Liu ve ark., *Deep learning seismic facies on state-of-the-art CNN architectures*, *Geophysics*, cilt 85, no. 5, ss. WA47–WA58, 2020.
- [10] Y. Dou ve ark., *A 2.5D Transformer U-Net for Seismic Fault Segmentation*, *Remote Sensing*, cilt 15, no. 22, 2023.
- [11] M. Abid ve ark., *An ensemble approach to seismic facies classification on the F3 dataset*, *Computational Intelligence and Neuroscience*, 2022.
- [12] *CONSS: Contrastive Semi-Supervised Learning for Seismic Facies Classification*, *IEEE JSTARS*, 2023.
- [13] *AdaSemSeg: Few-Shot Domain Adaptive Semantic Segmentation for Seismic Facies*, arXiv:2501.16760, 2025.
- [14] H. Sheng ve ark., *Seismic Foundation Model: A pre-trained model for seismic interpretation tasks*, arXiv:2309.02791, 2024.
- [15] *UmixClick: Interactive seismic facies segmentation with mixed representation*, *Nature Scientific Reports*, 2025, doi:10.1038/s41598-025-32016-8.